



Universidad de Concepción
Facultad de Ciencias Físicas y
Matemáticas
Departamento de Astronomía



Aplicación de Deep Learning en el estudio de la identificación de sistemas binarios con manchas estelares

Propuesta de Tesis para Título

Autor: Fernando Quiroz Escobar

Profesor Patrocinante: Ronald Mennickent Cid

Chile, Región del Biobío, Concepción

2 de junio de 2025

1. Dedicatoria

Dedicado a mi círculo íntimo, en el cual se encuentra mi familia: mi madre, Claudia Escobar, mi padre, José Mancilla, mis hermanas Ignacia Mancilla y Aylin Mancilla. Sin ellos y los valores que me han inculcado, no habría sido posible mi desarrollo como profesional ni como persona; por ustedes sueño y sigo soñando.

Dedicado a mi pareja, Millarai Rivero, que gracias a su amor y paciencia que me ha tenido en los momentos críticos de esta etapa, apoyándome tanto en los buenos momentos como en los malos, es que ha podido salir adelante esta investigación.

Me gustaría dedicar esta investigación a un gran amigo que tengo, Francisco Tapia. Fue de los únicos amigos que confió ciegamente en mis capacidades para lograr este sueño de ser astrónomo. Me encantaría que estuvieras conmigo para celebrar este gran paso, permíteme ser egoísta una última vez y observa este logro. Descansa en paz, amigo mío.

2. Agradecimientos

Quería darme este espacio para agradecer a mi profesor guía, el doctor Ronald Mennickent Cid, que me ha proporcionado la ayuda necesaria para sacar este proyecto adelante. Agradezco la confianza que tiene en mí para dar rienda suelta a mi creatividad.

De igual manera, me gustaría agradecer a mis colegas y amigos astrónomos: Tomás Cisternas, Joaquín Gallardo, Nicolás Castro, Marco Cárdenas, Bárbara Astete, Fabián Catalán, Anahis de la Barra, Bárbara Martínez, Jorge Muñoz, Jorge Saavedra, Juan Pablo Benavente, Daniel Daza, Joaquín Higuera, que me han ayudado de diferentes maneras a lo largo de esta larga carrera.

Por otro lado, también me gustaría agradecer al grupo "Stellar variability", en especial a Juan Garcés; gracias a su apoyo y paciencia, se logró llevar a cabo este proyecto.

Quisiera expresar mi sincero agradecimiento al Centro de Astrofísica y Tecnologías Afines (CATA), cuyo financiamiento a través del proyecto BASAL FB210003 fue fundamental para la realización de esta investigación.

Índice general

1. Dedicatoria	I
2. Agradecimientos	II
Índice general	III
3. Abstract	1
4. Introducción	3
5. Marco teórico	6
5.1. Sistemas Binarios	6
5.2. Diversidad de Sistemas Binarios y su Relevancia Magnética	8
5.2.1. Eclipsing Binary (EclBin)	9
5.2.2. Variables RS Canum Venaticorum (RSCVnV*)	9
5.2.3. Variables BY Draconis (BYDraV*)	11
5.2.4. Variables Rotacionales (RotV*)	11
5.2.5. Binarias Espectroscópicas (SB*)	12
5.2.6. Otros Tipos Observados y Consideraciones Adicionales	12
5.3. Manchas estelares	13
5.4. Diagramas O-C: Diagnóstico de la Dinámica y Actividad en Binarias de Contacto	15
5.5. Indices de correlación	22
5.5.1. Coeficiente de Correlación de Kendall (τ)	22

5.5.2.	Coeficiente de Correlación de Spearman (ρ)	23
5.5.3.	Coeficiente de Correlación de Pearson (r)	23
5.6.	Reducción de Dimensionalidad	24
5.6.1.	Análisis de Componentes Principales (PCA)	25
5.6.2.	t-Distributed Stochastic Neighbor Embedding (t-SNE)	25
5.6.3.	Uniform Manifold Approximation and Projection (UMAP)	27
5.7.	Fundamentos de las Redes Neuronales Convolucionales (CNNs)	28
5.7.1.	Arquitectura ResNet-50 y Aprendizaje Residual	31
6.	Metodología	34
6.1.	Preprocesamiento de Datos Observacionales de Kepler	34
6.2.	Análisis Exploratorio mediante Reducción de Dimensionalidad y Agrupamiento No Supervisado	37
6.2.1.	Aplicación de Técnicas de Reducción de Dimensionalidad	37
6.2.2.	Aplicación de Algoritmos de Agrupamiento (Clustering)	39
6.3.	Método ResNet-50	41
6.3.1.	Generación de Datos Sintéticos Multiclase	41
6.3.2.	Modelo de Red Neuronal Convolucional (ResNet50)	44
6.3.3.	Entrenamiento y Evaluación del Modelo	46
6.3.4.	Rendimiento del Modelo CNN en el Conjunto de Prueba Sintético	46
7.	Análisis	50
7.1.	Resultados	50

7.2.	Análisis de las Clases Predichas en Función del Período Orbital y Tipo de Binaria	50
7.3.	Clase C0: Patrones Anticorrelacionados (Indicativos de Manchas Estelares)	52
7.4.	Clase C1: Patrones Correlacionados Oscilatorios (Indicativos de LTTE)	54
7.5.	Clase C2: Patrones Correlacionados Parabólicos (Indicativos de Cambio Secular de Período)	55
7.6.	Clase C3: Patrones Planos o Ruidosos (Sin Señal O-C Clara)	57
7.7.	Clase C4: Patrones Mixtos o Complejos	59
7.8.	Clase C5: Cambios Abruptos de Período	61
7.9.	Comparación con Clasificaciones Previas: El Caso de los Sistemas de Balaji et al. (2014)	62
8.	Discusión	66
8.1.	Limitaciones del Enfoque Basado en Correlaciones Globales y Agrupamiento No Supervisado	66
8.2.	Interpretación de las Poblaciones Clasificadas y Consistencia Física	67
8.3.	Correlación entre Patrones O-C Predichos y Tipos de Sistemas Binarios	70
9.	conclusión	73
10.	Anexo	88
10.1.	hiperparámetros de los coeficientes	88
10.2.	Hiperparámetros del modelo	97
10.3.	Tablas con los resultados	98

3. Abstract

El análisis de los diagramas de variación de tiempos de eclipse (O-C) es una técnica fundamental para investigar la dinámica orbital y la actividad física en sistemas binarios. Las desviaciones de una efemérides lineal pueden revelar fenómenos como la presencia de compañeros terciarios (Light Travel Time Effect, LTTE), cambios seculares en el período orbital, o la influencia de la actividad magnética estelar, como manchas que migran en la superficie estelar y producen patrones O-C anticorrelacionados [Tran et al., 2013, Balaji et al., 2015]. La identificación y clasificación de estos diversos patrones en los grandes volúmenes de datos de misiones como Kepler es un desafío que requiere herramientas eficientes y robustas.

Este trabajo de tesis presenta el desarrollo y la aplicación de un modelo de aprendizaje profundo, basado en una Red Neuronal Convolutiva (CNN) con arquitectura ResNet-50, para la clasificación automática de seis patrones morfológicos O-C distintos. Para entrenar el modelo, se generó un extenso conjunto de datos sintéticos de 60,000 curvas O-C, representadas como imágenes minimalistas normalizadas, simulando: (C0) comportamiento anticorrelacionado (manchas), (C1) correlacionado oscilatorio (LTTE), (C2) correlacionado parabólico (cambio secular), (C3) plano/ruidoso (sin señal clara), (C4) mixto/complejo (superposición de efectos), y (C5) cambios abruptos de período. El modelo entrenado alcanzó una precisión superior al 99 % en la clasificación de estos patrones sintéticos en un conjunto de prueba no visto.

Posteriormente, el modelo se aplicó a un conjunto de **1438** sistemas binarios observacionales del catálogo Kepler, cuyas curvas O-C fueron preprocesadas (incluyendo un suavizado y normalización visual) para generar imágenes de entrada. El análisis de las clases predichas, en conjunto con información sobre el período orbital y el tipo de binaria conocido para cada sistema, reveló distribuciones y correlaciones con implicancias astrofísicas significativas. Se identificaron **230** sistemas con patrones predominantemente anticorrelacionados (C0), **140** candidatos a sistemas

triples con firma de LTTE (C1), y poblaciones notables en las demás categorías, incluyendo una alta incidencia de patrones mixtos/complejos (C4), especialmente en sistemas de período corto. Un análisis exploratorio previo, utilizando únicamente coeficientes de correlación y algoritmos de agrupamiento no supervisado (DBSCAN) sobre proyecciones de baja dimensión (PCA, t-SNE, UMAP), demostró ser insuficiente para esta clasificación fina, subrayando la ventaja del enfoque de aprendizaje profundo.

La contribución principal de este trabajo radica en la demostración de la eficacia de las CNNs para la clasificación detallada y multiclase de una amplia gama de morfologías O-C, superando las limitaciones de los análisis basados en características globales simples. Este método ofrece una herramienta potente y escalable para la caracterización de grandes conjuntos de datos de variaciones de tiempo de eclipse, proporcionando nuevas perspectivas sobre la prevalencia y coexistencia de diversos fenómenos físicos en sistemas binarios y facilitando la selección de candidatos para estudios de seguimiento.

4. Introducción

La identificación y estudio de manchas estelares es un área crucial en la astronomía moderna, ya que estas estructuras superficiales están estrechamente relacionadas con la actividad magnética y la evolución estelar [Strassmeier, 2009, Berdyugina, 2005]. Las manchas estelares, análogas a las manchas solares pero a menudo cubriendo fracciones superficiales significativamente mayores, son regiones de la fotosfera estelar que presentan temperaturas más bajas que el resto de la estrella. Esta diferencia de temperatura, originada por la inhibición de la convección por fuertes campos magnéticos locales [Parker, 1979], las hace visibles debido a su menor emisión de luz en el continuo óptico. Estas manchas pueden influir significativamente en la variabilidad de la luminosidad estelar (conocida como variabilidad rotacional), un fenómeno bien documentado en estrellas de tipos espectrales tardíos [Hall and Busby, 1990], y se ha sugerido que también pueden jugar un rol en la inflación del radio observada en algunas estrellas activas, especialmente en estrellas jóvenes y de baja masa [Morales et al., 2008, Stassun et al., 2012].

En las últimas décadas, el advenimiento de grandes sondeos astronómicos y misiones espaciales como Kepler [Borucki et al., 2010] y TESS [Ricker et al., 2015] ha permitido la recopilación de cantidades masivas de datos fotométricos de alta precisión y cadencia. Este diluvio de datos ha impulsado el uso de técnicas de Aprendizaje Automático (*Machine Learning*, ML) y Aprendizaje Profundo (*Deep Learning*, DL) para analizar y extraer información de fenómenos astronómicos complejos [Feigelson and Babu, 2012, Ivezić et al., 2014, Mehta et al., 2019]. Estos modelos predictivos pueden procesar grandes conjuntos de datos para identificar patrones sutiles, como la variabilidad en las curvas de luz causada por manchas estelares [e.g., Basri et al., 2011, Davenport et al., 2014], y mejorar significativamente la precisión y eficiencia en la detección y caracterización de estas y otras estructuras o eventos.

El uso de técnicas de ML en astronomía ha demostrado ser efectivo en diversas aplicaciones,

incluyendo la clasificación de espectros estelares [Bailer-Jones et al., 2008], la detección de exoplanetas [Shallue and Vanderburg, 2018], la identificación de patrones en curvas de luz por brokers de alertas como ALeRCE [Förster et al., 2021], y la caracterización de poblaciones estelares. La aplicación de algoritmos de aprendizaje automático a datos estelares permite identificar poblaciones candidatas a pertenecer a cúmulos estelares y realizar búsquedas por edad utilizando fotometría y movimientos propios [e.g., Cantat-Gaudin et al., 2018]. Además, el análisis wavelet y otras técnicas de procesamiento de series temporales son útiles para detectar periodicidades y fenómenos transitorios en las curvas de luz de diversos tipos de estrellas [Scargle, 1982].

En esta tesis se aborda la identificación y caracterización automatizada de diversos fenómenos físicos que se manifiestan en los sistemas binarios mediante el análisis de las variaciones en los tiempos de sus eclipses, reflejadas en los diagramas O-C (Observado menos Calculado) [Ste, 2005]. Si bien los índices de correlación tradicionales (Pearson, Spearman, Kendall) y los métodos de agrupamiento no supervisado pueden ofrecer una primera aproximación para distinguir tendencias generales en estos diagramas (ver Sección 6.2), a menudo resultan insuficientes para capturar la rica variedad de morfologías complejas y sutiles asociadas con diferentes procesos astrofísicos. Para superar estas limitaciones, en el presente trabajo se explora el potencial de las Redes Neuronales Convolucionales (CNNs) profundas, específicamente la arquitectura ResNet-50 [He et al., 2016a], para clasificar los diagramas O-C representados como imágenes. La motivación fundamental de este enfoque radica en la capacidad inherente de las CNNs para aprender jerarquías de características visuales directamente de los datos [LeCun et al., 1998], permitiendo el reconocimiento de patrones complejos que podrían no ser evidentes para métricas globales o análisis manuales a gran escala. El objetivo principal es desarrollar y evaluar un modelo capaz de distinguir entre múltiples categorías de comportamiento O-C, incluyendo patrones anticorrelacionados (indicativos de actividad de manchas estelares; Tran et al., 2013, Balaji et al., 2015), patrones correlacionados oscilatorios (sugestivos de Light Travel Time Effect por terceros cuerpos; Irwin, 1952), tendencias parabólicas (asociadas a cambios seculares de período; Hilditch, 2001), patrones

planos o ruidosos (indicando estabilidad o baja señal), comportamientos mixtos/complexos (superposición de efectos) y cambios abruptos de período. Para lograr esto, se generan representaciones visuales normalizadas y minimalistas de las curvas O-C, tanto sintéticas como observacionales, optimizadas para ser procesadas por la arquitectura ResNet-50, con el fin de proporcionar una herramienta robusta y escalable para la caracterización de grandes catálogos de sistemas binarios.

5. Marco teórico

5.1. Sistemas Binarios

Un sistema binario estelar se define como un conjunto de dos estrellas unidas por su mutua atracción gravitatoria, las cuales orbitan alrededor de un centro de masas compartido. Aunque nuestra percepción cotidiana se centra en el Sol como una estrella aislada, la realidad astronómica indica que los sistemas múltiples son una configuración muy frecuente. Investigaciones sugieren que más de la mitad de las estrellas de tipo solar [Duquennoy and Mayor, 1991] y una fracción aún mayor de las estrellas más masivas [Sana et al., 2012] forman parte de sistemas binarios o de mayor multiplicidad. Esta notable prevalencia resalta la necesidad de estudiar estos sistemas para obtener una comprensión completa de la formación estelar, la evolución galáctica y la demografía de las poblaciones estelares [Eggleton, 2006].

La interacción y el movimiento dentro de un sistema binario se rigen fundamentalmente por las leyes de la gravitación de Newton y las leyes de Kepler, adaptadas para describir el movimiento de dos cuerpos masivos [Smart, 1977]. Cada estrella traza una órbita elíptica en torno al centro de masas común, siendo la órbita circular un caso particular. Las propiedades orbitales clave, como el período, la excentricidad y la separación entre las componentes, están determinadas por las masas estelares involucradas y por las condiciones físicas presentes durante la formación del sistema [Bodenheimer et al., 2007].

La naturaleza de la interacción entre las estrellas de un sistema binario depende críticamente de su proximidad relativa y de la fase evolutiva en la que se encuentre cada una. Se distinguen principalmente tres configuraciones [Paczynski, 1971]: sistemas desligados (*detached*), donde las estrellas evolucionan casi independientemente; sistemas semidesligados (*semi-detached*), en los que una estrella expandida transfiere masa a su compañera al llenar su Lóbulo de Roche, a menudo

formando un disco de acreción [Frank et al., 2002]; y sistemas de contacto (*contact binaries*), donde ambas estrellas comparten una envoltura gaseosa común debido a su extrema cercanía [Lucy, 1968, Rucinski, 1998].

Un factor observacional crucial es la inclinación del plano orbital del sistema respecto a la línea de visión del observador terrestre. Si esta inclinación es cercana a los 90 grados (visión "de canto"), se producirán eclipses periódicos cuando una estrella transite por delante de la otra. Estos sistemas se conocen como binarias eclipsantes y sus curvas de luz muestran disminuciones características de brillo durante los eventos de eclipse (véase figura 1).




Figura 1: Ilustración de la curva de luz de un sistema estelar binario eclipsante. El panel superior muestra las variaciones de brillo observadas a medida que las estrellas orbitan y se ocultan mutuamente. Los paneles inferiores representan las posiciones relativas de la estrella más grande y fría (naranja) y la estrella más pequeña y caliente (azul) en cuatro fases clave: (1) y (3) brillo máximo sin eclipse, (2) mínimo primario cuando la estrella azul es ocultada, y (4) mínimo secundario cuando la estrella azul transita parcialmente por delante de la naranja.

Las binarias eclipsantes son herramientas poderosas para determinar con precisión los radios

estelares a partir de la duración y forma de los eclipses. Combinando radios con temperaturas efectivas (derivadas de espectros o colores), se pueden calcular las luminosidades estelares. Estos parámetros empíricos (masa, radio, luminosidad, temperatura) son esenciales para calibrar y validar los modelos teóricos de estructura y evolución estelar [[Andersen, 1991](#), [Torres et al., 2010](#)].

Los sistemas binarios cercanos también son clave para investigar el magnetismo estelar. Las fuerzas de marea pueden sincronizar la rotación de las estrellas con el período orbital [[Hut, 1981](#)], manteniendo rotaciones rápidas que potencian los dínamos internos [[Parker, 1955](#), [Charbonneau, 2014](#)] y generan altos niveles de actividad magnética. Esto se manifiesta en forma de grandes manchas estelares, fáculas intensas y erupciones energéticas, características de tipos como las variables RS Canum Venaticorum (RS CVn) y BY Draconis (BY Dra) [[Strassmeier, 2009](#), [Hall, 1976](#)]. Estos sistemas son, por tanto, escenarios ideales para estudiar la influencia de la interacción binaria en la generación y manifestación de campos magnéticos estelares.

5.2. Diversidad de Sistemas Binarios y su Relevancia Magnética

Las clasificaciones de sistemas binarios pueden basarse en el método de detección (visual, espectroscópico, eclipsante, astrométrico) o en sus propiedades físicas. La base de datos de Kepler Eclipsing Binaries (KEB), por ejemplo, utiliza principalmente información fotométrica de alta precisión para clasificar los objetos. Si bien el catálogo KEB es amplio, para una investigación centrada en estrellas magnéticas, ciertos tipos de binarias adquieren una relevancia particular. A continuación, se describen los tipos más significativos en este contexto, ilustrados con las categorías del KEB:

5.2.1. Eclipsing Binary (EclBin)

Constituyen la clase más numerosa en catálogos como el KEB (2434 sistemas). Su detección se basa en las caídas periódicas de brillo causadas por los eclipses mutuos. El análisis detallado de sus curvas de luz permite determinar radios estelares relativos y absolutos, temperaturas superficiales relativas, inclinación orbital y, en combinación con datos espectroscópicos, masas precisas. La fotometría de alta cadencia y precisión, como la de Kepler, revela además efectos sutiles como la reflexión de la luz entre componentes, la distorsión elipsoidal debida a las mareas, la presencia de **manchas estelares** (indicativas de actividad magnética) que modulan la luz fuera de los eclipses, y variaciones en los tiempos de los eclipses (ETVs) que pueden indicar la presencia de cuerpos adicionales en el sistema.

5.2.2. Variables RS Canum Venaticorum (RSCVnV*)

Los sistemas estelares RS Canum Venaticorum (RS CVn) constituyen una clase significativa de estrellas binarias cercanas (78 en KEB), definidas originalmente por sus características de actividad y configuración orbital ([Fitch \[1976\]](#)). Se caracterizan fundamentalmente por niveles excepcionales de actividad magnética en sus atmósferas exteriores, muy superiores a los observados en estrellas individuales de tipos espectrales similares ([Strassmeier \[2009\]](#)). Típicamente, estos sistemas están compuestos por dos estrellas de tipos espectrales tardíos (usualmente F, G o K), donde al menos una de ellas ha evolucionado fuera de la secuencia principal, encontrándose comúnmente en estado de subgigante o gigante ([Avvakumova et al. \[2013\]](#)). La proximidad orbital (con períodos que usualmente van de menos de un día a unas pocas decenas de días) induce fuertes interacciones de marea, resultando frecuentemente en la sincronización (o cuasi-sincronización) de los períodos de rotación estelar con el periodo orbital, factor clave para su actividad ([Fitch \[1976\]](#); [Strassmeier \[2009\]](#)).

La elevada actividad magnética de los sistemas RS CVn se manifiesta a través de diversos fenómenos observables. Prominentes líneas de emisión cromosférica, como las resonantes Ca II H y K y la línea H α del hidrógeno, son consistentemente detectadas con gran intensidad, indicando cromosferas muy activas (e.g., [Montes et al. \[1995\]](#); [Strassmeier \[2009\]](#)). Paralelamente, presentan una fuerte y variable emisión de rayos X, originada en coronas extendidas y extremadamente calientes (con temperaturas de decenas de millones K), que es órdenes de magnitud superior a la solar ([Güdel \[2004\]](#); [Uchida et al. \[1996\]](#)). También se detecta emisión de radio variable e intensa, a menudo asociada a potentes erupciones (flares) no térmicas que pueden superar energéticamente a las erupciones solares por varios órdenes de magnitud ([Güdel \[2004\]](#)).

Una de las consecuencias más distintivas de esta intensa actividad magnética superficial es la presencia casi ubicua de manchas estelares (starspots) de gran extensión y larga duración ([Fitch \[1976\]](#); [Strassmeier \[2009\]](#)). Estas regiones, análogas a las manchas solares pero cubriendo una fracción significativamente mayor de la superficie estelar (pudiendo alcanzar 10-30 % o más en algunos casos), son producto de la emergencia de fuertes flujos magnéticos que inhiben localmente la convección fotosférica ([Berdyugina \[2005\]](#)). La rotación de la estrella transporta estas grandes manchas a través del disco visible, generando una modulación característica y cuasi-periódica en la curva de luz del sistema, conocida como “onda de distorsión” fotométrica ([Fitch \[1976\]](#); [Berdyugina \[2005\]](#)). Esta variabilidad rotacional, considerada un sello distintivo de los sistemas RS CVn, no solo confirma la presencia de las manchas sino que también permite estudiar su evolución y distribución, a menudo mediante técnicas como el mapeo Doppler (e.g., [Collier Cameron \[1999\]](#); ?).

El motor físico subyacente a toda esta fenomenología es un mecanismo de dinamo magnético altamente eficiente, potenciado por la rápida rotación y la convección ([Strassmeier \[2009\]](#)). Se acepta que la rotación estelar rápida, forzada o mantenida por las interacciones de marea en la binaria cercana, interactúa vigorosamente con las zonas convectivas presentes en las envolturas de

estas estrellas de tipo tardío, amplificando potentemente los campos magnéticos (Parker [1970]; Strassmeier [2009]). Estos campos magnéticos intensificados son, en última instancia, los responsables de calentar las capas atmosféricas superiores, generar las extensas manchas fotosféricas y alimentar las energéticas erupciones (Güdel [2004]; Berdyugina [2005]). Por ello, los sistemas RS CVn son laboratorios astrofísicos cruciales para investigar la física del dinamo estelar bajo condiciones extremas, la conexión entre parámetros estelares y actividad magnética, y la influencia de la binaridad en la evolución y manifestación de la actividad estelar (Strassmeier [2009]; Güdel [2004]).

5.2.3. Variables BY Draconis (BYDraV*)

Variables de tipo espectral K o M (enanas frías, 13 sistemas en KEB) que muestran variabilidad fotométrica cuasi-periódica atribuida a la rotación de estrellas con **grandes manchas superficiales o regiones cromosféricamente activas**. Al igual que las RS CVn, su actividad está ligada a la rotación y al magnetismo, siendo relevantes para estudios de dinamos en estrellas frías, a menudo influenciadas por la presencia de una compañera.

5.2.4. Variables Rotacionales (RotV*)

La variabilidad observada en estas estrellas (60 en KEB) se debe a la presencia de inhomogeneidades en su superficie (principalmente **manchas estelares frías o regiones brillantes activas**) que son llevadas a través del disco visible por la rotación estelar. Este tipo de variabilidad es frecuente en estrellas de tipos espectrales tardíos y en componentes de binarias cercanas donde la rotación está sincronizada con la órbita, relacionando directamente la rotación con manifestaciones de campos magnéticos superficiales.

5.2.5. Binarias Espectroscópicas (SB*)

Estos sistemas (105 en KEB) se identifican por el desplazamiento Doppler periódico de las líneas en sus espectros. Si se detectan las líneas de ambas estrellas (SB2), se pueden determinar las razones de masas y, a menudo, las masas individuales si se conoce la inclinación (por ejemplo, si también es una EclBin). Si solo se ven las líneas de una estrella (SB1), se puede obtener una función de masa. El conocimiento preciso de los parámetros estelares y orbitales es fundamental para contextualizar la actividad magnética observada en las componentes.

5.2.6. Otros Tipos Observados y Consideraciones Adicionales

El catálogo KEB incluye una variedad de otras clasificaciones con diferente número de representantes y relevancia variable para el estudio directo del magnetismo estelar. Entre ellos se encuentran:

- **Estrellas Químicamente Peculiares (ChemPec):** Aunque solo 4 sistemas se listan en KEB bajo esta designación, son de **alta importancia para el magnetismo**, ya que a menudo incluyen estrellas Ap/Bp con campos magnéticos globales intensos y estables. Su baja representación en KEB podría deberse a los criterios de selección del catálogo, que prioriza variables eclipsantes.
- **Variables Delta Scuti (delSctV):** Comprenden 46 sistemas en KEB. Son estrellas pulsantes de tipo A o F. La interacción entre pulsación, rotación (potencialmente afectada por mareas en binarias) y binaridad es de interés, aunque la conexión directa con fuertes campos magnéticos no es una característica definitoria de toda la clase.
- **Estrellas en la Rama de las Gigantes Rojas (RGB):** Con 36 sistemas, son relevantes para estudiar la interacción binaria en etapas tardías, que puede incluir transferencia de masa y

alteraciones en la rotación estelar, factores que pueden influir en la actividad magnética de las componentes.

- **Hot Subdwarfs (HotSubdwarf)**: Estos 5 sistemas representan estrellas evolucionadas, calientes y compactas. Una fracción significativa se halla en binarias de período corto, y algunas pueden poseer campos magnéticos detectables, posiblemente ligados a interacciones binarias previas.
- **Variables Eruptivas (Eruptive)**: Con 22 sistemas, esta categoría puede incluir estrellas con erupciones (flares) de origen magnético, aunque la naturaleza de la variabilidad puede ser diversa.

Además, el catálogo contiene tipos con muy baja representación numérica o de naturaleza más genérica: estrellas con líneas de emisión (**EmLine**^{*}, 6), estrellas en la rama horizontal (**HorBranch**^{*}, 5), variables RR Lyrae (**RRLyrae**, 5), variables Gamma Doradus (**gammaDorV**^{*}, 4), enanas blancas (**WhiteDwarf**, 1, algunas de las cuales pueden ser altamente magnéticas), estrellas rezagadas azules (**BlueStraggler**, 1, a menudo resultado de interacciones binarias y con rotación rápida), variables elipsoidales (**EllipVar**, 1), entre otras. Categorías como ^{*} ^{*} (Estrella Doble, 49), **Star** (Estrella, 32), y **Variable**^{*} (3) son más genéricas e indican que se requiere un análisis adicional para una clasificación física precisa. La investigación detallada de candidatos individuales dentro de estas categorías podría revelar sistemas magnéticamente activos.

5.3. Manchas estelares

Las manchas estelares son regiones en la superficie de una estrella que presentan temperaturas significativamente más bajas que las zonas circundantes debido a la influencia de campos magnéticos intensos. Estos campos magnéticos inhiben los procesos de transporte de energía en el interior estelar, en particular la convección, que es el mecanismo principal por el cual el calor

asciende desde las capas internas hacia la superficie de la estrella ([Schrijver and Zwaan \[2000\]](#)). Esta inhibición provoca un enfriamiento localizado, lo que hace que las manchas aparezcan más oscuras en comparación con el resto de la fotosfera ([Pontin and Priest \[2022\]](#)).

El campo magnético que da origen a las manchas estelares surge de procesos de dínamo en el interior de la estrella. Este fenómeno es generado por la interacción entre la rotación diferencial de la estrella y los movimientos convectivos de su plasma ionizado, que producen corrientes eléctricas que a su vez crean los intensos campos magnéticos ([Parker \[1955\]](#)). La concentración de líneas de campo magnético en ciertas regiones actúa como una barrera, restringiendo el movimiento del plasma caliente hacia la superficie y, por lo tanto, reduciendo la transferencia de energía térmica ([Babcock \[1961\]](#)).

En términos de dinámica estelar, las manchas son una manifestación visible de la actividad magnética en la atmósfera de la estrella. El fuerte gradiente de presión y densidad entre las zonas magnéticamente activas y el plasma circundante genera corrientes locales, que pueden ser responsables de fenómenos como erupciones y eyecciones de masa ([Aschwanden \[2005\]](#)). La estructura física de una mancha estelar incluye una región central más fría y oscura, conocida como "umbra", rodeada por una zona algo más cálida pero aún más fría que la fotosfera, llamada "penumbra". Estas características han sido extensamente estudiadas en el caso del Sol, sirviendo como modelo para comprender manchas en otras estrellas ([Stix \[2002\]](#)).

En el caso del Sol, las manchas solares tienen temperaturas de 3,500°C a 4,500°C, en contraste con los 5,500°C de la fotosfera ([Stix \[2002\]](#)). Esta diferencia de temperatura se traduce en una emisión reducida de radiación según la ley de Stefan-Boltzmann, lo que hace que las manchas aparezcan más oscuras ([Gray \[2005\]](#)). La variabilidad en el número de manchas solares a lo largo del tiempo está vinculada al ciclo magnético de 11 años del Sol, conocido como el ciclo solar, que implica la inversión periódica de los polos magnéticos solares ([Hathaway \[2015\]](#)).

En otras estrellas, las manchas estelares suelen ser más grandes y complejas debido a diferencias en la intensidad y configuración de los campos magnéticos. En estrellas jóvenes y de tipo T Tauri, por ejemplo, la rápida rotación y las intensas corrientes convectivas producen campos magnéticos más fuertes que generan manchas significativamente mayores en tamaño y número (Johns-Krull [2007]). Esto también implica una mayor modulación del brillo estelar a medida que las manchas giran con la estrella, creando curvas de luz características (Balaji et al. [2015]).

El estudio físico de las manchas estelares ofrece información valiosa no solo sobre los campos magnéticos y la actividad de las estrellas, sino también sobre su estructura interna y evolución. Al analizar las variaciones de brillo que provocan, se pueden determinar propiedades clave como el período de rotación estelar y las diferencias de temperatura en la superficie (See et al. [2014]). La rotación, a su vez, es un parámetro fundamental que modula la formación y evolución de estas manchas. La modulación de la curva de luz generada por su presencia permite estimar la cobertura total de manchas y así corregir la luminosidad y temperatura aparentes de la estrella (Serna [2023]). Estudiar la rotación, particularmente en estrellas jóvenes, es crucial para entender la interacción con sus discos protoplanetarios, ya que estos pueden frenar la velocidad de giro estelar (Serna [2023]). En conjunto, el análisis de las manchas y la rotación proporciona datos esenciales para modelar cómo los campos magnéticos impactan los flujos de energía y masa, influenciando la evolución de la estrella y su interacción con sistemas planetarios cercanos (See et al. [2014], Serna [2023]).

5.4. Diagramas O-C: Diagnóstico de la Dinámica y Actividad en Binarias de Contacto

El análisis de los diagramas O-C (Observado menos Calculado) constituye una técnica astrofísica de alta precisión, extensamente utilizada para investigar las variaciones temporales en los momentos de los eclipses de sistemas binarios. Esta metodología es particularmente poderosa en el estudio de binarias de contacto, sistemas estelares donde dos estrellas de secuencia principal,

típicamente de tipos espectrales F, G o K [Rucinski, 1998], se encuentran tan próximas que sus atmósferas exteriores se fusionan en una envoltura convectiva común [Lucy, 1968]. La construcción de un diagrama O-C implica la sustracción de los tiempos de los mínimos de luz calculados mediante una efemérides lineal (asumiendo un período orbital constante) de los tiempos observados. Las desviaciones resultantes, o residuos O-C, magnifican perturbaciones sutiles en el sistema, ya sean de origen intrínseco a la binaria o debidas a influencias externas.

La morfología de las curvas O-C del eclipse primario y secundario, y su relación mutua, son diagnósticos clave. Se pueden identificar dos patrones principales con implicaciones físicas distintas:

1. **Variaciones O-C Anticorrelacionadas:** Este patrón se caracteriza por desviaciones en los tiempos de los mínimos primario y secundario que ocurren en direcciones opuestas. Es decir, un adelanto en un mínimo tiende a coincidir con un retraso en el otro, y viceversa (véase figura 2). La explicación predominante para este fenómeno en binarias de contacto de corto período es la **presencia y migración de grandes manchas estelares fotosféricas (o grupos de manchas)** en la superficie de una de las componentes [Tran et al., 2013, Balaji et al., 2015, Kalimeris et al., 2002]. Estas manchas, manifestaciones de la actividad magnética estelar intensificada por la rápida rotación y las profundas zonas convectivas de estas estrellas [Lanza and Rodonò, 1999], alteran la distribución del brillo superficial. Si una mancha es visible durante una fracción significativa de la órbita, su rotación (posiblemente diferencial respecto a la fotosfera subyacente o asíncrona con la órbita) modula la forma de la curva de luz, desplazando el centro fotométrico de la estrella y, consecuentemente, los tiempos medidos de los mínimos de forma diferencial.




Figura 2: Ejemplos de diagramas O-C para sistemas binarios de contacto observados por Kepler que muestran un **patrón predominantemente anticorrelacionado** entre las curvas O-C del eclipse primario y secundario. En estos casos, un adelanto en el tiempo de un mínimo se corresponde con un retraso en el otro, y viceversa, creando una apariencia de "imagen especular". Este comportamiento es una firma característica del efecto modulador de manchas estelares que migran en longitud sobre la superficie de una de las componentes. La cuantificación de esta relación puede realizarse mediante el coeficiente de correlación de Pearson entre las dos series temporales O-C.

2. **Variaciones O-C Correlacionadas:** En este caso, las desviaciones temporales de ambos mínimos (primario y secundario) ocurren en la misma dirección; ambos se adelantan o ambos se retrasan conjuntamente (véase figura 3).

- Si el patrón correlacionado es **oscilatorio o cuasi-periódico**, la causa más probable y extensamente documentada es el **Efecto Roemer, también conocido como Light Travel Time Effect (LTTE)**. Esta variación es una firma robusta de la **presencia de un tercer cuerpo masivo orbitando el sistema binario central**, formando así un sistema jerárquico triple [e.g., [Irwin, 1952](#), [Frieboes-Conde and Herczeg, 1970](#), [Borkovits et al., 2005](#), [Rappaport et al., 2013](#)]. El movimiento orbital de la binaria interior alrededor del centro de masa común del sistema triple induce variaciones periódicas en la distancia entre la binaria y el observador terrestre. Consecuentemente, el tiempo que tarda la luz de los eclipses en alcanzar la Tierra se modula, causando que ambos mínimos se observen sistemáticamente antes o después de lo predicho por una efemérides lineal. La amplitud de esta variación O-C está directamente relacionada con el semieje mayor proyectado de la órbita de la binaria alrededor del tercer cuerpo ($a_B \sin(i_3)$), y el período de la oscilación O-C corresponde al período orbital del tercer compañero (P_3). El análisis detallado de estas curvas O-C correlacionadas permite derivar parámetros orbitales del sistema triple, como P_3 , la excentricidad e_3 , la longitud del periastro ω_3 , y una función de masa para el tercer cuerpo [[Mayer, 1990](#), [Borkovits and Bíró, 1999](#)]. Estudios como el de [Conroy et al. \[2014\]](#), utilizando datos de Kepler, han identificado numerosos candidatos a sistemas triples precisamente a través del análisis de estas variaciones O-C correlacionadas, demostrando la eficacia del método. Estos autores, por ejemplo, reportaron 31 nuevos candidatos a binarias eclipsantes en sistemas triples, muchos de los cuales no hubieran sido identificados por otros medios.
- Si el patrón correlacionado es una **tendencia secular (ej., parabólica continua)**, esto generalmente se interpreta como un **cambio progresivo y constante en el período**

orbital de la binaria interna. Dicho cambio puede ser causado por mecanismos de transferencia de masa conservativa o no conservativa entre las componentes, o por pérdida de momento angular del sistema (ej., a través de vientos estelares magnetizados o frenado magnético, aunque la radiación gravitacional es típicamente despreciable para los períodos de las binarias de contacto) [Hilditch, 2001, Qian, 2001].

El estudio seminal de Tran et al. [2013] sobre binarias de contacto de la misión Kepler se centró predominantemente en las variaciones anticorrelacionadas. Analizaron aproximadamente 2000 sistemas, identificando 390 que exhibían variaciones O-C con características de “random walk” o cuasi-periodicidades, con amplitudes típicas de ± 200 -300 segundos. La observación más significativa fue la **naturaleza predominantemente anticorrelacionada** de las variaciones O-C entre los eclipses primarios y secundarios, especialmente en sistemas con períodos orbitales del orden de 0.35 días (ver Figura 2 para ejemplos ilustrativos de este patrón). Tran et al. [2013] argumentaron convincentemente que este comportamiento no podía ser atribuido a la transferencia de masa (que requeriría tasas de transferencia implausiblemente altas y produciría efectos correlacionados) ni a órbitas ligeramente excéntricas (que requerirían excentricidades incompatibles con la naturaleza de contacto de estos sistemas). En cambio, propusieron que la **migración de manchas estelares**, con cambios en su longitud estelar a lo largo de semanas o meses, era el mecanismo subyacente. Esta migración se asocia con la rotación diferencial, un fenómeno bien documentado en estrellas de tipo solar [Hall and Busby, 1990]. Las escalas de tiempo de las variaciones O-C (50–200 días) permitieron a Tran et al. [2013] estimar el coeficiente k de dependencia latitudinal de la rotación estelar, obteniendo valores en el rango de 0.003–0.013, consistentes con observaciones solares y de otras estrellas activas.

El trabajo de Balaji et al. [2015] profundizó en esta línea, implementando un sofisticado método de ajuste de la curva de luz en segmentos para rastrear explícitamente la fase (ϕ_1) asociada al efecto de la mancha, interpretada como la longitud estelar efectiva de la mancha o del centro de actividad.




Figura 3: Ejemplos de diagramas O-C para sistemas binarios de Kepler que exhiben un **comportamiento correlacionado** entre las variaciones temporales de los eclipses primario y secundario. Se observa cómo ambas curvas O-C (representando los dos mínimos) tienden a subir y bajar conjuntamente, siguiendo patrones oscilatorios similares. Este tipo de variación es una fuerte indicación de la presencia de un tercer cuerpo orbitando la binaria (Efecto Roemer o LTTE), que modula el tiempo de viaje de la luz de ambos eclipses de manera análoga.

Este enfoque no solo confirmó la validez del modelo de manchas migratorias propuesto por [Tran et al. \[2013\]](#), sino que también permitió una cuantificación más detallada de la dinámica de las manchas. [Balaji et al. \[2015\]](#) encontraron que aproximadamente el 34 % de los sistemas con O-C anticorrelacionado mostraban un movimiento aparente de las manchas en sentido retrógrado (respecto al marco orbital co-rotante), mientras que un 13 % exhibía un movimiento progrado. Estos hallazgos subrayan que la rotación de las regiones fotosféricas activas no está, en general, perfectamente sincronizada con el período orbital en una porción significativa de estas binarias de contacto. Adicionalmente, el formalismo de [Balaji et al. \[2015\]](#), a través del análisis de la fase del término $\cos(2\omega t)$ (ϕ_2), proporcionó una vía complementaria para identificar señales de LTTE indicativas de terceros cuerpos, como también fue explotado en los trabajos de [Rappaport et al. \[2013\]](#) y [Conroy et al. \[2014\]](#) para la búsqueda sistemática de sistemas triples en los datos de Kepler.

5.5. Índices de correlación

Para cuantificar la relación estadística entre las curvas de luz (o características derivadas de ellas) correspondientes a los eclipses primarios y secundarios, se emplean índices de correlación. El objetivo es determinar si existe una dependencia sistemática entre cómo se comporta una curva (p.ej., variaciones en su forma, profundidad, o duración a lo largo del tiempo o bajo diferentes condiciones) y cómo se comporta la otra. Se utilizan tres índices principales para capturar diferentes tipos de relaciones:

5.5.1. Coeficiente de Correlación de Kendall (τ)

El coeficiente de Kendall (τ) mide la concordancia ordinal entre las dos series de datos (una para el eclipse primario, otra para el secundario). Evalúa si, al comparar pares de puntos correspondientes (p.ej., en la misma observación o fase orbital relativa), el orden relativo de los valores tiende a ser el mismo en ambas series. Es decir, si un punto es "mayor" que otro en la serie del primario, ¿tiende a ser también mayor en la serie del secundario?

Se calcula como:

$$\tau = \frac{N_C - N_D}{\frac{1}{2}n(n-1)} \quad (1)$$

Donde N_C es el número de pares concordantes, N_D el de pares discordantes, y n el número total de puntos comparados. Un valor de τ cercano a +1 indica una fuerte concordancia en el ordenamiento (correlación positiva de rangos), cercano a -1 indica una fuerte discordancia (anticorrelación de rangos), y cercano a 0 indica independencia ordinal. Es útil por ser no paramétrico.

5.5.2. Coeficiente de Correlación de Spearman (ρ)

El coeficiente de Spearman ρ mide la fuerza y dirección de una relación monotónica entre las dos series. Determina si, a medida que los valores en la serie del eclipse primario tienden a aumentar, los valores en la serie del secundario también tienden consistentemente a aumentar (correlación monotónica positiva, $\rho \approx 1$) o a disminuir (correlación monotónica negativa o anticorrelación, $\rho \approx -1$). No requiere que la relación sea lineal, solo que sea direccionalmente consistente.

Se basa en los rangos de los datos y su fórmula es:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (2)$$

Donde d_i es la diferencia de rangos para la i -ésima observación y n es el número total de observaciones. Un ρ cercano a 0 indica ausencia de una tendencia monotónica clara. También es un método no paramétrico.

5.5.3. Coeficiente de Correlación de Pearson (r)

El coeficiente de correlación de Pearson (r) mide específicamente la fuerza y dirección de una relación lineal entre las dos series de datos. Evalúa qué tan bien se puede describir la relación entre los valores del eclipse primario (X) y los del secundario (Y) mediante una línea recta.

La ecuación es:

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \quad (3)$$

Donde X_i, Y_i son los valores, $\bar{X}, \bar{Y}$ son las medias, y n el número de puntos.

- $r \approx +1$: Indica una fuerte correlación lineal positiva (cuando X aumenta, Y aumenta proporcionalmente).
- $r \approx -1$: Indica una fuerte correlación lineal negativa o anticorrelación (cuando X aumenta, Y disminuye proporcionalmente).
- $r \approx 0$: Indica ausencia de relación lineal entre X e Y.

Este índice es sensible a la linealidad de la relación y a valores atípicos.

5.6. Reducción de Dimensionalidad

En el análisis de datos complejos y de alta dimensionalidad, como los que a menudo se encuentran en la astrofísica, las técnicas de reducción de dimensionalidad juegan un papel crucial. Estos métodos buscan transformar los datos de un espacio de alta dimensión a un espacio de menor dimensión, idealmente preservando la estructura intrínseca y las relaciones más importantes presentes en los datos originales. Los objetivos principales de la reducción de dimensionalidad incluyen la mitigación de la "maldición de la dimensionalidad" (problemas que surgen al trabajar con muchas variables), la reducción del ruido, la facilitación de la visualización de los datos y la mejora de la eficiencia y el rendimiento de algoritmos de aprendizaje automático posteriores, como los de agrupamiento (clustering) o clasificación [van der Maaten et al., 2009, Sorzano et al., 2014].

Las técnicas de reducción de dimensionalidad se pueden clasificar ampliamente en lineales y no lineales. Los métodos lineales, como el Análisis de Componentes Principales (PCA), buscan proyecciones lineales de los datos, mientras que los métodos no lineales, como t-SNE y UMAP, son capaces de capturar estructuras más complejas y no lineales en los datos.

5.6.1. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales (PCA) es una de las técnicas de reducción de dimensionalidad lineal más fundamentales y ampliamente utilizadas [Jolliffe, 2002]. Su objetivo es transformar un conjunto de variables posiblemente correlacionadas en un conjunto de nuevas variables linealmente no correlacionadas, denominadas componentes principales. Estos componentes se ordenan de tal manera que el primer componente principal captura la mayor varianza posible en los datos, el segundo componente principal captura la segunda mayor varianza (y es ortogonal al primero), y así sucesivamente.

Matemáticamente, dado un conjunto de datos X de N observaciones con D variables, PCA busca una transformación lineal W tal que $Y = XW$, donde Y es la representación de los datos en el nuevo espacio de dimensionalidad $d < D$. Las columnas de W son los vectores propios (eigenvectors) de la matriz de covarianza de X (o de la matriz de correlación si los datos están estandarizados), correspondientes a los d mayores valores propios (eigenvalues). La magnitud de cada valor propio indica la cantidad de varianza explicada por su correspondiente componente principal. Si bien PCA es eficiente y fácil de interpretar, su naturaleza lineal limita su capacidad para capturar estructuras no lineales complejas en los datos.

5.6.2. t-Distributed Stochastic Neighbor Embedding (t-SNE)

t-SNE (t-Distributed Stochastic Neighbor Embedding) es una técnica de reducción de dimensionalidad no lineal, particularmente efectiva para la visualización de datos de alta dimensionalidad en espacios de baja dimensión (típicamente 2D o 3D) [van der Maaten and Hinton, 2008]. Su principal fortaleza radica en su capacidad para preservar la estructura local de los datos, agrupando puntos que son similares en el espacio de alta dimensión y separando aquellos que son disímiles.

El algoritmo t-SNE opera en dos etapas. Primero, construye una distribución de probabilidad sobre pares de puntos en el espacio de alta dimensión. La similitud del punto de datos x_j con el punto de datos x_i se modela como la probabilidad condicional $p_{j|i}$ de que x_i elegiría a x_j como su vecino, calculada bajo una distribución Gaussiana centrada en x_i :

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$

donde σ_i es la varianza de la Gaussiana, ajustada para cada punto x_i en función de un hiperparámetro denominado *perplejidad*, que puede interpretarse como un número efectivo de vecinos locales. Las probabilidades conjuntas p_{ij} se definen como $p_{ij} = (p_{j|i} + p_{i|j}) / 2N$.

Segundo, t-SNE define una distribución de probabilidad similar q_{ij} sobre los puntos y_i y y_j (las representaciones de x_i y x_j) en el mapa de baja dimensión, utilizando una distribución t de Student con un grado de libertad (equivalente a una distribución de Cauchy):

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

La elección de la distribución t de Student, con sus colas más pesadas que la Gaussiana, ayuda a mitigar los problemas de “agrupamiento excesivo”(crowding problem) y a separar mejor los clústeres disímiles.

El objetivo de t-SNE es encontrar una configuración de puntos y_i en el espacio de baja dimensión que minimice la divergencia de Kullback-Leibler (KL) entre las distribuciones de probabilidad conjuntas $P = \{p_{ij}\}$ y $Q = \{q_{ij}\}$:

$$C(Y) = D_{KL}(P||Q) = \sum_i \sum_{j \neq i} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

Esta minimización se realiza típicamente mediante descenso de gradiente. Es importante destacar que t-SNE se enfoca en preservar la estructura local; por lo tanto, las distancias relativas entre

clústeres bien separados en la visualización t-SNE no necesariamente reflejan las distancias globales en el espacio original, y el tamaño de los clústeres puede no ser directamente interpretable [Wattenberg et al., 2016]. Variantes como Barnes-Hut t-SNE [van der Maaten, 2014] mejoran su eficiencia computacional para grandes conjuntos de datos.

5.6.3. Uniform Manifold Approximation and Projection (UMAP)

UMAP (Uniform Manifold Approximation and Projection) es otra potente técnica de reducción de dimensionalidad no lineal que, al igual que t-SNE, es efectiva para la visualización y también puede utilizarse para la reducción de dimensionalidad general [McInnes et al., 2018]. UMAP se basa en fundamentos matemáticos de la topología algebraica y la teoría de variedades (Riemannian geometry and manifold learning).

El algoritmo UMAP opera construyendo primero un grafo ponderado en el espacio de alta dimensión, donde los pesos representan la probabilidad de que dos puntos estén conectados. Luego, busca una incrustación (embedding) de baja dimensión que tenga una estructura topológica lo más similar posible a la del grafo de alta dimensión. De forma simplificada, el proceso implica:

1. **Construcción de un Grafo Ponderado en Alta Dimensión:** Para cada punto, UMAP encuentra sus k vecinos más cercanos. Luego, construye una representación difusa de la variedad (manifold) subyacente asignando pesos a las aristas de este grafo. Estos pesos se normalizan para que la suma de los pesos de las aristas que salen de cada vértice sea uno (formando una especie de matriz de adyacencia simétrica).
2. **Optimización de una Incrustación de Baja Dimensión:** UMAP define una función de coste similar a la de t-SNE (basada en la divergencia de entropía cruzada) que mide la diferencia entre las estructuras topológicas del grafo de alta dimensión y una representación análoga en baja dimensión. Esta función de coste se optimiza mediante descenso de gradiente

estocástico para encontrar las posiciones de los puntos en el espacio de baja dimensión.

UMAP a menudo ofrece ventajas sobre t-SNE en términos de tiempo de ejecución, especialmente para grandes conjuntos de datos, y se argumenta que puede preservar mejor la estructura global de los datos en comparación con t-SNE, además de la estructura local [McInnes et al., 2018]. Al igual que t-SNE, UMAP tiene hiperparámetros clave, como el número de vecinos ($n_{neighbors}$) y la distancia mínima entre puntos en la incrustación (min_{dist}), que influyen en la visualización resultante.

5.7. Fundamentos de las Redes Neuronales Convolucionales (CNNs)

Las Redes Neuronales Convolucionales (CNNs) constituyen una clase especializada de modelos de aprendizaje profundo, optimizadas intrínsecamente para el procesamiento de datos que exhiben una estructura de rejilla (grid-like topology), tales como imágenes o, como en el presente estudio, representaciones visuales de series temporales como los diagramas O-C (Observado menos Calculado) [LeCun et al., 1998, Goodfellow et al., 2016]. En el dominio astrofísico, la aplicación de CNNs al análisis de diagramas O-C permite superar las limitaciones inherentes a arquitecturas neuronales más simples, particularmente en el manejo de la alta dimensionalidad de las entradas visuales y en la preservación de la información espacial local. Esta capacidad es esencial para la identificación de los patrones morfológicos sutiles y a menudo complejos que caracterizan los diversos fenómenos físicos subyacentes a las variaciones temporales de los eclipses en sistemas binarios, tales como la actividad de manchas estelares o la presencia de compañeros terciarios. La eficacia de las CNNs se fundamenta en dos principios arquitectónicos clave: la **localidad de conexiones** (neuronas en una capa solo se conectan a una pequeña región de la capa anterior) y la **compartición de parámetros** (el mismo conjunto de pesos se utiliza para múltiples neuronas en una capa).

La unidad operativa fundamental de una CNN es la **capa convolucional**. Esta capa aplica un conjunto de filtros aprendibles, también denominados kernels (K), que se deslizan (convolucionan) a través del volumen de entrada X (en este trabajo, una imagen en escala de grises derivada de las curvas O-C) para producir un conjunto de mapas de características (o mapas de activación) Y . Cada filtro está diseñado para detectar la presencia de patrones espaciales específicos en la entrada, desde características simples como bordes o texturas en las primeras capas, hasta motivos más complejos y abstractos en capas más profundas. La operación de convolución discreta para una neurona en la posición (i, j) del k -ésimo mapa de características de salida se define formalmente como:

$$Y_{i,j,k} = f \left(b_k + \sum_{c=1}^{C_{in}} \sum_{h=1}^{H_f} \sum_{w=1}^{W_f} K_{h,w,c,k} \cdot X'_{i \cdot S_h + h, j \cdot S_w + w, c} \right) \quad (4)$$

donde X' representa el volumen de entrada (posiblemente modificado por un relleno o *padding* para gestionar los efectos de borde), $K_{h,w,c,k}$ es el peso del filtro en la posición (h, w) para el canal de entrada c (donde C_{in} es el número total de canales de entrada; $C_{in} = 1$ para imágenes en escala de grises) y el filtro de salida k . Los términos H_f y W_f son las dimensiones espaciales (alto y ancho) del filtro. El término b_k es el sesgo (*bias*) asociado al k -ésimo filtro. S_h y S_w son los pasos (*strides*) de la convolución en las direcciones vertical y horizontal, respectivamente. Finalmente, f es una función de activación no lineal. El principio de **compartición de parámetros**, que implica la reutilización del mismo conjunto de pesos del filtro K_k a través de todas las posiciones espaciales (i, j) de la entrada, reduce drásticamente el número total de parámetros aprendibles del modelo. Esta propiedad no solo mejora la eficiencia del entrenamiento y reduce el riesgo de sobreajuste, sino que también dota a la capa convolucional de **equivarianza a la traslación**: la capacidad de un filtro para detectar un patrón específico es independiente de la posición absoluta de dicho patrón en la imagen de entrada [Goodfellow et al., 2016].

Otros componentes arquitectónicos cruciales que típicamente se integran en una CNN inclu-

yen:

- **Función de Activación No Lineal:** Aplicada elemento a elemento después de la operación de convolución (y la adición del sesgo), su propósito es introducir no linealidades en el modelo, permitiéndole aprender mapeos más complejos entre la entrada y la salida. La Unidad Lineal Rectificada (**ReLU**), definida como $f(x) = \max(0, x)$, es una elección prevalente debido a su simplicidad computacional y su eficacia en mitigar el problema del desvanecimiento del gradiente durante el entrenamiento de redes profundas [Nair and Hinton, 2010, Glorot et al., 2011].
- **Capa de Agrupación (Pooling):** Esta capa tiene como objetivo reducir progresivamente la dimensionalidad espacial (ancho y alto) de los mapas de características, lo que resulta en una disminución del número de parámetros y de la carga computacional en capas subsecuentes. Además, confiere al modelo un grado de robustez (invarianza local) a pequeñas traslaciones o distorsiones en la entrada. Las operaciones de agrupación más comunes son *Max Pooling* ($y = \max_{i \in R} x_i$) y *Average Pooling* ($y = \frac{1}{|R|} \sum_{i \in R} x_i$), donde la operación se aplica sobre una región local R del mapa de características.
- **Capa Totalmente Conectada (Fully Connected Layer):** Usualmente ubicadas hacia el final de la arquitectura de la CNN, estas capas conectan cada neurona de la capa anterior con cada neurona de la capa actual, similar a las redes neuronales tradicionales (perceptrón multicapa). Su función es integrar la información global extraída por las capas convolucionales y de agrupación precedentes para realizar la tarea final, como la clasificación (asignando la entrada a una de varias categorías predefinidas) o la regresión.

La disposición jerárquica de estas capas permite a las CNNs aprender de forma automática y adaptativa una representación de los datos progresivamente más abstracta y semánticamente rica, desde características visuales de bajo nivel hasta conceptos de alto nivel [Zeiler and Fergus,

2014]. En el contexto de este trabajo, esto se traduce en la capacidad del modelo para aprender las morfologías distintivas asociadas a cada una de las clases de patrones O-C definidas.

5.7.1. Arquitectura ResNet-50 y Aprendizaje Residual

El entrenamiento de redes neuronales convolucionales muy profundas, si bien teóricamente deseable para aprender representaciones más complejas, históricamente ha enfrentado desafíos significativos, principalmente el **problema de la degradación** del rendimiento (donde añadir más capas conduce a un mayor error de entrenamiento) y el fenómeno de la **desaparición de gradientes** (donde los gradientes se vuelven excesivamente pequeños a medida que se retropropagan a través de muchas capas, dificultando el aprendizaje en las capas iniciales) [He et al., 2016a, Bengio et al., 1994, Hochreiter, 1998]. Las Redes Residuales (ResNets), introducidas por He et al. [2016a], abordan estos problemas de manera elegante y efectiva mediante la incorporación del concepto de **aprendizaje residual** a través de **conexiones de salto** (*shortcut connections* o *skip connections*).

La idea central de las ResNets es reformular lo que cada bloque de capas (denominado bloque residual) debe aprender. En lugar de esperar que una pila de capas aprenda directamente una función de mapeo subyacente deseada $H(x)$ a partir de una entrada x , se entrena al bloque para que aprenda una función residual $\mathcal{F}(x, \{W_i\})$, donde $\{W_i\}$ representa el conjunto de pesos aprendibles dentro de ese bloque. La salida del bloque $H(x)$ se calcula entonces como la suma de la función residual y la entrada original (la conexión de salto):

$$H(x) = \mathcal{F}(x, \{W_i\}) + x \quad (5)$$

Esta formulación aditiva presenta ventajas cruciales para el entrenamiento de redes profundas:

- **Facilitación del Aprendizaje de la Identidad:** Si la transformación óptima que una sección

de la red necesita aprender es simplemente la identidad (es decir, $H(x) = x$), el bloque residual solo necesita aprender $\mathcal{F}(x, \{W_i\}) = 0$. Se postula que es más fácil para las capas no lineales llevar sus pesos a cero que aprender una transformación de identidad. Esto ayuda a prevenir que la adición de más capas degrade el rendimiento del modelo; en el peor de los casos, las capas adicionales pueden aprender la identidad.

- **Mejora del Flujo de Gradientes:** Las conexiones de salto proporcionan rutas alternativas y directas para que los gradientes se retropropagen a través de la red, desde las capas más profundas hasta las más superficiales. Esto alivia significativamente el problema de la desaparición de gradientes, permitiendo el entrenamiento efectivo de arquitecturas considerablemente más profundas que las redes convolucionales tradicionales [He et al., 2016b].

En los casos en que las dimensiones de la entrada x y la salida de la función residual $\mathcal{F}(x, \{W_i\})$ no coinciden (por ejemplo, debido a un cambio en el número de canales de características o a una operación de *pooling* que reduce la dimensión espacial), la conexión de salto x se modifica mediante una transformación lineal W_s (usualmente implementada como una capa convolucional de 1×1 con el *stride* adecuado) para que las dimensiones sean compatibles para la suma: $H(x) = \mathcal{F}(x, \{W_i\}) + W_s x$.

ResNet-50, la arquitectura específica empleada en este estudio, es una red neuronal convolucional de 50 capas que implementa estos principios de aprendizaje residual. Utiliza una estructura de bloques "cuello de botella" (*bottleneck design*) para lograr una mayor profundidad con una eficiencia computacional relativamente alta. Cada bloque cuello de botella consiste en una secuencia de tres capas convolucionales: una convolución de 1×1 para reducir la dimensionalidad de los canales, seguida de una convolución de 3×3 (la convolución principal), y finalmente otra convolución de 1×1 para restaurar o aumentar la dimensionalidad de los canales. Las conexiones de salto se implementan alrededor de estos bloques.

El éxito y la robustez de ResNet-50 la han consolidado como una arquitectura de referencia en visión por computadora, siendo ampliamente utilizada para el **aprendizaje por transferencia** (*transfer learning*). Mediante esta técnica, un modelo ResNet-50 pre-entrenado en un conjunto de datos masivo y diverso (como ImageNet [[Deng et al., 2009](#), [Krizhevsky et al., 2012](#)]) puede ser adaptado (afinado o *fine-tuned*) para una nueva tarea con un conjunto de datos específico, como la clasificación de patrones en imágenes O-C. Esto es particularmente valioso cuando los conjuntos de datos específicos de la tarea son limitados en tamaño, ya que los pesos pre-entrenados encapsulan un conocimiento rico sobre características visuales generales que pueden ser transferidas y refinadas [[Kornblith et al., 2019](#)]. En el presente trabajo, se parte de una ResNet-50 pre-entrenada, modificando su primera capa convolucional para aceptar imágenes en escala de grises de un solo canal y reemplazando su capa de clasificación final para adaptarla al número de clases de patrones O-C definidas.

6. Metodología

El objetivo de este trabajo es desarrollar un modelo de aprendizaje profundo capaz de clasificar automáticamente los patrones observados en los diagramas de variación de tiempos de eclipse (O-C) de sistemas binarios. A continuación, se detalla el preprocesamiento de los datos observacionales, la generación de un conjunto de datos sintéticos robusto para el entrenamiento, la arquitectura del modelo convolucional empleado y el procedimiento de entrenamiento y evaluación.

6.1. Preprocesamiento de Datos Observacionales de Kepler

El análisis se fundamenta en datos precalculados de variación de tiempos de eclipse (O-C) para sistemas binarios del catálogo Kepler, presumiblemente derivados de las curvas de luz de la misión en modo de Larga Cadencia (Long-Cadence). Se procesaron archivos individuales que contienen las series temporales O-C (en días) para cada sistema, donde los eclipses primarios y secundarios están debidamente identificados (e.g., mediante una columna 'Eclipse' con valores 1 y 2, respectivamente).

Para cada sistema, se extrajeron las series de residuos O-C correspondientes a los eclipses primarios y secundarios. Dado el inherente ruido de alta frecuencia o la dispersión punto a punto presente en los datos O-C, se implementó un paso opcional de suavizado para resaltar tendencias subyacentes. Específicamente, se exploró la aplicación de una media móvil centrada (utilizando `pandas.Series.rolling(window=WINDOW_SIZE, center=True, min_periods=1).mean()`) tanto a la serie O-C primaria como a la secundaria de forma independiente. Se experimentó con diferentes tamaños de ventana (`WINDOW_SIZE`), por ejemplo, `WINDOW_SIZE = 5` para un suavizado moderado y `WINDOW_SIZE = 3` para una intervención más discreta. Este procedimiento reemplaza

cada punto O-C por el promedio de sí mismo y sus vecinos dentro de la ventana definida. Las imágenes generadas a partir de los datos suavizados con `WINDOW_SIZE = 3` (ver Figura 4) se utilizaron como entrada principal para el modelo en una de las fases de análisis, aunque también se consideraron los datos sin suavizar para evaluar la robustez del clasificador.

Independientemente del suavizado, un paso crucial para la preparación de las imágenes de entrada a la Red Neuronal Convolutiva (CNN) fue la **normalización visual**. Para cada par de series O-C (primaria y secundaria, ya sean crudas o suavizadas), se calcularon los valores mínimo y máximo del conjunto combinado de ambas series. Luego, todos los puntos de ambas series se reescalaron linealmente para que el rango completo de variación del par de curvas estuviera comprendido entre -1 y 1.

Finalmente, se generaron representaciones gráficas minimalistas para cada sistema. Estas imágenes muestran únicamente las dos curvas O-C (normalizadas y, opcionalmente, suavizadas) superpuestas, sin ejes, etiquetas, títulos, rejillas u otros elementos gráficos (`plt.axis('off')`), guardadas con `bbox_inches='tight'`, `pad_inches=0`. El tamaño de estas imágenes se fijó en 256×64 píxeles con un DPI de 100, manteniendo una proporción de aspecto adecuada para la visualización de series temporales. Estas imágenes constituyen la entrada directa a nuestro modelo de clasificación. Adicionalmente, se calculó y almacenó el coeficiente de correlación de Pearson entre la serie O-C primaria y secundaria (después del suavizado, si se aplicó) para cada sistema.

Diagramas O-C de Sistemas Binarios




Figura 4: Plots de los diagramas O-C de los sistemas binarios KIC 12508348, KIC 2715007, KIC 5891963, KIC 9110213 (izquierda a derecha de arriba a abajo) , en los cuales se pueden observar la reducción de ruido producida. El hecho de que sean diagramas O-C minimalistas se debe justamente a que ayuda a la eficiencia y la atención controlada que puede llegar a tener el modelo predictivo.

6.2. Análisis Exploratorio mediante Reducción de Dimensionalidad y Agrupamiento No Supervisado

Antes de proceder con el desarrollo del modelo de aprendizaje profundo basado en CNNs, se llevó a cabo un análisis exploratorio con el objetivo de evaluar si un conjunto reducido de características globales, derivado de las curvas O-C, era suficiente para discriminar entre los diferentes patrones de comportamiento temporal. Específicamente, se utilizaron los tres coeficientes de correlación calculados para cada sistema (Pearson r , Spearman ρ , y Kendall τ) como entrada para técnicas de reducción de dimensionalidad y algoritmos de agrupamiento no supervisado.


6.2.1. Aplicación de Técnicas de Reducción de Dimensionalidad

Los tres coeficientes de correlación para cada sistema binario conforman un vector de características en un espacio tridimensional. Para facilitar la visualización de la estructura inherente de estos datos y como paso previo a la aplicación de algoritmos de agrupamiento, se emplearon las siguientes técnicas de reducción de dimensionalidad para proyectar los datos a un espacio bidimensional:


- **Análisis de Componentes Principales (PCA):** Se aplicó PCA para transformar los tres coeficientes de correlación en dos componentes principales, capturando la máxima varianza lineal en los datos.
- **t-Distributed Stochastic Neighbor Embedding (t-SNE):** Se utilizó t-SNE con el objetivo de obtener una representación bidimensional que preservara las relaciones de vecindad local entre los sistemas en el espacio de características de correlación. Se exploraron diferentes valores del hiperparámetro de perplejidad (de 15 a 30) para optimizar la visualización.
- **Uniform Manifold Approximation and Projection (UMAP):** Se aplicó UMAP como una

alternativa moderna a t-SNE, buscando una representación bidimensional que potencialmente preserve mejor tanto la estructura local como la global de los datos. Se experimentó con los hiperparámetros ' $n_{neighbors}$ ' (10 a 50) y ' min_{dist} ' (0.01 a 0.5).


Reducción de Dimensionalidad de Índices de Correlación O-C



(a) PCA



(b) t-SNE



(c) UMAP


Figura 5: Visualizaciones bidimensionales de los sistemas binarios obtenidas mediante (a) PCA, (b) t-SNE, y (c) UMAP, aplicadas a los coeficientes de correlación de Pearson, Spearman y Kendall. Aunque se observan ciertas estructuras y agrupaciones, la separación clara en las seis clases físicas de interés no es evidente en ninguna de las proyecciones.

6.2.2. Aplicación de Algoritmos de Agrupamiento (Clustering)


Sobre las representaciones bidimensionales obtenidas mediante UMAP y t-SNE (ver Figura 6), se aplicó el algoritmo de agrupamiento DBSCAN (Density-Based Spatial Clustering of Applications with Noise). DBSCAN fue seleccionado por su capacidad para encontrar clústeres de forma arbitraria y su habilidad para identificar puntos como ruido (outliers), sin requerir la especificación previa del número de clústeres [Ester et al., 1996].

Se llevó a cabo una exploración sistemática de los hiperparámetros para las técnicas de reducción de dimensionalidad y para DBSCAN con el fin de obtener las representaciones y agrupaciones más informativas. Los rangos explorados y los valores finalmente seleccionados para las visualizaciones y análisis principales se resumen en la Tabla 10. La selección de los valores finales se basó en la inspección visual de las proyecciones y los clústeres resultantes, buscando un equilibrio entre la separación de grupos y la coherencia estructural.


Reducción de Dimensionalidad de Índices de Correlación O-C



(a) PCA



(b) t-SNE



(c) UMAP

Figura 6: Visualizaciones bidimensionales de los sistemas binarios obtenidas mediante (a) PCA, (b) t-SNE, y (c) UMAP, aplicadas a los coeficientes de correlación de Pearson, Spearman y Kendall a los cuales fue aplicado DBSCAN para hacer la separación de los clusters.

6.3. Método ResNet-50

6.3.1. Generación de Datos Sintéticos Multiclase

Para entrenar de manera robusta el modelo de clasificación, se generó un extenso y diverso conjunto de datos sintéticos. Este proceso se realizó mediante scripts de Python, utilizando principalmente las librerías NumPy para los cálculos numéricos y Matplotlib para la generación de las representaciones visuales. El objetivo fue crear una colección balanceada de 60,000 imágenes (con 10,000 ejemplos por clase) de pares de series temporales O-C, simulando seis patrones morfológicos distintivos observados en datos reales o predichos por modelos físicos. Estos patrones son:

1. **C0: Anticorrelacionado (Manchas Estelares):** Pares de curvas predominantemente sinusoidales donde una es aproximadamente la inversión de la otra, simulando el efecto de manchas estelares migratorias [Tran et al., 2013, Balaji et al., 2015]. Se generaron variando amplitud (e.g., 50-250 unidades arbitrarias), frecuencia (períodos de 125-500 días simulados) y fase, con ligeras diferencias en amplitud y fase entre la curva primaria y secundaria.
2. **C1: Correlacionado Oscilatorio (LTTE):** Pares de curvas sinusoidales que se mueven en fase, simulando el Light Travel Time Effect debido a un tercer cuerpo. Se usaron amplitudes mayores (e.g., 100-600 unidades) y períodos más largos (e.g., 400-2500 días) en comparación con C0, con pequeñas variaciones aleatorias entre las curvas primaria y secundaria.
3. **C2: Correlacionado Parabólico (Cambio Secular de Período):** Pares de curvas que siguen una tendencia parabólica (cóncava o convexa), representando cambios de período orbital progresivos. Los parámetros de la parábola (curvatura, posición del vértice, término lineal) se variaron aleatoriamente.
4. **C3: Plano / Ruidoso (Sin Señal Clara):** Pares de curvas dominadas por ruido gaussiano

alrededor de una línea base cercana a cero, pudiendo incluir una señal subyacente de muy baja amplitud. El nivel de ruido se varió (e.g., σ entre 30-150 unidades).

5. **C4: Mixto / Complejo:** Curvas generadas por la superposición de dos o más patrones, típicamente una señal correlacionada de largo período (como LTTE de C1) y una señal anticorrelacionada de corto período (como manchas de C0). Los parámetros de cada componente se variaron independientemente.
6. **C5: Cambio Abrupto de Período (Correlacionado):** Curvas que presentan un salto o discontinuidad repentina en el nivel O-C en un punto temporal aleatorio, seguido por una nueva tendencia (plana o con pendiente). La magnitud del salto y las pendientes antes/después se variaron.

Para todos los tipos de curvas sintéticas, se añadió ruido gaussiano con niveles variables para simular la dispersión observacional. Un aspecto fundamental fue la **normalización visual** de cada par de curvas sintéticas generadas (primaria y secundaria): antes de guardar la imagen, el conjunto combinado de ambas curvas se reescaló para que su rango completo de valores estuviera entre -1 y 1. Posteriormente, se generaron imágenes PNG minimalistas de 256×64 píxeles (DPI 100), mostrando únicamente las dos curvas normalizadas superpuestas, sin ningún otro elemento gráfico (ver Figura 7). Simultáneamente, se creó un archivo de metadatos (CSV) que asocia cada nombre de archivo de imagen con su etiqueta de clase numérica (0 a 5). Este conjunto de datos sintéticos etiquetados y visualmente consistentes forma la base para el entrenamiento y validación del modelo CNN.




Figura 7: Ejemplos representativos de las seis clases de patrones O-C sintéticos generados para el entrenamiento del modelo. Cada imagen muestra un par de curvas (primaria y secundaria) normalizadas visualmente y sin elementos gráficos adicionales, listas para ser procesadas por la CNN.

6.3.2. Modelo de Red Neuronal Convolutacional (ResNet50)

Para la tarea de clasificación de los patrones O-C a partir de sus representaciones visuales, se empleó una Red Neuronal Convolutacional (CNN) basada en la arquitectura ResNet50 [He et al., 2016a]. Se utilizaron los pesos pre-entrenados en el conjunto de datos ImageNet [Deng et al., 2009] como punto de partida, una técnica común de aprendizaje por transferencia para mejorar el rendimiento y acelerar la convergencia.

Dado que las imágenes de entrada O-C son en escala de grises (1 canal) y no las imágenes RGB (3 canales) para las que ResNet50 fue originalmente diseñada, la primera capa convolutacional del modelo (conv1) fue modificada para aceptar una entrada de 1 canal en lugar de 3. Los pesos de esta capa se inicializaron de forma estándar tras la modificación. La capa final completamente conectada (fc) del modelo ResNet50 fue reemplazada por una nueva capa lineal con un número de neuronas de salida igual al número de clases definidas en nuestra tarea de clasificación (seis clases, como se describe en la Sección 6.3.1), esta modificación se puede ver en la figura 8.




Figura 8: Adaptación de la arquitectura ResNet-50 para la tarea de clasificación. Se mantiene la estructura fundamental de la ResNet-50 original, incluyendo los cuatro stages con 3, 4, 6 y 3 bloques residuales 'bottleneck' ($\text{cfg}=[3,4,6,3]$), que permiten el entrenamiento efectivo de redes profundas mediante conexiones de salto. Las adaptaciones para este estudio comprenden la modificación de la capa convolucional de entrada para operar con imágenes de un solo canal (escala de grises) y el ajuste de la capa de salida para la clasificación en 6 clases. Más específico en [10.1](#)

6.3.3. Entrenamiento y Evaluación del Modelo

El conjunto de datos sintéticos (60,000 imágenes) se dividió en conjuntos de entrenamiento (72 %), validación (8 %) y prueba (20 %), asegurando una estratificación por clase para mantener proporciones similares en cada conjunto. Las imágenes se reescalaron a 224×224 píxeles, el tamaño de entrada estándar para ResNet50, y los valores de los píxeles se normalizaron.

El entrenamiento del modelo se configuró con los hiperparámetros y componentes que se resumen en la Tabla 12. Se entrenó utilizando la función de pérdida de entropía cruzada (CrossEntropyLoss), adecuada para tareas de clasificación multiclase. Se empleó el optimizador AdamW [Loshchilov and Hutter, 2019] con una tasa de aprendizaje inicial de 3×10^{-4} . Se implementó un planificador de tasa de aprendizaje (ReduceLROnPlateau) que reduce la tasa de aprendizaje si la métrica de validación (precisión) no mejora durante un número determinado de épocas. Adicionalmente, se utilizó una estrategia de parada temprana (early stopping) para finalizar el entrenamiento si la precisión de validación no mejoraba después de 7 épocas consecutivas, con el fin de evitar el sobreajuste y guardar el modelo con el mejor rendimiento en el conjunto de validación. El entrenamiento se realizó utilizando precisión mixta automática (**torch.amp**) para acelerar los cálculos en GPUs compatibles.

6.3.4. Rendimiento del Modelo CNN en el Conjunto de Prueba Sintético

Antes de aplicar el modelo ResNet-50 entrenado a los datos observacionales de Kepler, se evaluó su rendimiento de manera rigurosa utilizando el conjunto de prueba sintético, compuesto por **12,000** imágenes (2,000 por cada una de las seis clases) que el modelo no había visto durante el entrenamiento ni la validación. Esta evaluación es crucial para cuantificar la capacidad del modelo para generalizar y distinguir los patrones morfológicos O-C ideales con los que fue entrenado.

Los resultados de esta evaluación se resumen en la Tabla 1 y la Figura 9. El modelo alcanzó una precisión (*accuracy*) global sobresaliente de **99.90 %** en el conjunto de prueba sintético. El análisis detallado por clase, presentado en el reporte de clasificación, revela valores de precisión, exhaustividad (*recall*) y puntuación F1 consistentemente altos, cercanos al 100 % para la mayoría de las clases. Específicamente, las clases **C0_Anticorrelated** y **C3_Flat_Noisy** fueron clasificadas con un 100 % de precisión y exhaustividad. Las clases **C1_Correlated_Oscillatory_LTTE**, **C2_Correlated_Parabolic**, **C4_Mixed_Complex**, y **C5_Abrupt_Change** también mostraron un rendimiento excepcional, con puntuaciones F1 superiores al 99.8 %.

Tabla 1: Métricas de rendimiento del modelo ResNet-50 en el conjunto de prueba sintético (12,000 imágenes, 6 clases).

Métrica	Valor (%)
Accuracy Global	99.90
F1-score (Macro Average)	99.90
F1-score (Weighted Average)	99.90

El reporte de clasificación detallado por clase y la matriz de confusión se presentan en la Figura 9 y en el texto. Las métricas por clase individuales (precisión, recall, F1) fueron consistentemente $\geq 99,8 \%$.

La matriz de confusión (Figura 9) ilustra visualmente este alto rendimiento, con una diagonal fuertemente dominante, indicando que la gran mayoría de las muestras fueron clasificadas correctamente. Los pocos errores de clasificación son mínimos (e.g., 3 sistemas de la clase **C1** clasificados erróneamente como **C2**, 4 de **C4** como **C1**). Estas pequeñas confusiones pueden atribuirse a la inherente similitud morfológica en casos límite entre ciertos patrones sintéticos, especialmente cuando se considera el ruido añadido.




Figura 9: Matriz de confusión donde se puede observar los fallos y aciertos en cada clase producida por el modelo

En conjunto, estos resultados demuestran que el modelo CNN entrenado es altamente competente para identificar y distinguir los seis patrones O-C definidos cuando se le presentan ejemplos sintéticos relativamente limpios y característicos. Este alto rendimiento en datos sintéticos proporciona una base de confianza para su posterior aplicación a los datos observacionales reales, aunque se anticipa que la complejidad y el ruido inherentes a los datos reales presentarán un desafío mayor para la generalización del modelo.

Es importante destacar que un rendimiento tan elevado en el conjunto de prueba sintético, **el cual fue consistente con el alto y estable rendimiento observado en el conjunto de validación durante las épocas de entrenamiento**, no implica necesariamente sobreajuste (*overfitting*) en el sentido clásico de memorización del ruido del conjunto de entrenamiento a expensas de la generalización a datos no vistos de la misma distribución. Indica, más bien, que el modelo ha aprendido exitosamente a generalizar las características distintivas de los seis patrones O-C definidos. La capacidad de la arquitectura ResNet-50, junto con la relativa claridad y distinguibilidad de las morfologías de las clases sintéticas generadas, contribuye a este alto nivel de rendimiento.

La principal consideración al interpretar estos resultados no es el sobreajuste a los datos sintéticos per se, sino el posible **desajuste de dominio (*domain shift*)** al aplicar el modelo a datos observacionales reales. Los datos reales son inherentemente más complejos, contienen artefactos instrumentales, ruido no gaussiano y una variabilidad astrofísica que podría no estar completamente representada en el conjunto de datos sintéticos, por muy diverso que este sea. Por lo tanto, si bien estos resultados en datos sintéticos establecen una base sólida para la capacidad del modelo de reconocer los patrones ideales, el rendimiento en datos reales será el verdadero indicador de su utilidad práctica y de los desafíos de generalización.

En conjunto, estos resultados demuestran que el modelo CNN entrenado es altamente competente para identificar y distinguir los seis patrones O-C definidos cuando se le presentan ejemplos sintéticos relativamente limpios y característicos. Este alto rendimiento en datos sintéticos proporciona una base de confianza para su posterior aplicación a los datos observacionales reales, aunque se anticipa que la complejidad y el ruido inherentes a los datos reales presentarán un desafío mayor para la generalización del modelo.

7. Análisis

7.1. Resultados

7.2. Análisis de las Clases Predichas en Función del Período Orbital y Tipo de Binaria

Una vez obtenidas las predicciones de clase para los **1438** sistemas Kepler mediante el modelo ResNet-50, se procedió a un análisis contextual para interpretar estos resultados en el marco de las propiedades físicas conocidas de dichos sistemas. Para cada una de las seis clases de patrones O-C predichas (**C0** a **C5**), se investigó la distribución de los sistemas en función de dos parámetros fundamentales: su período orbital y su clasificación astrofísica como `binary_type` (obtenida de catálogos externos).

El período orbital es un factor determinante en la dinámica y evolución de los sistemas binarios, especialmente en aquellos con componentes cercanas. Para este análisis, se estableció un umbral de período de **1 día** para segmentar la muestra. La elección de este umbral se fundamenta en varias consideraciones:

- **Prevalencia de Binarias de Contacto y Efectos de Marea:** Los sistemas binarios con períodos orbitales inferiores a aproximadamente 1 día suelen ser binarias de contacto o sistemas semidesprendidos muy cercanos donde las interacciones de marea son extremadamente fuertes [Hilditch, 2001, Rucinski, 1998]. Estas interacciones tienden a circularizar las órbitas y a sincronizar los períodos de rotación de las componentes con el período orbital [Hut, 1981]. La rotación rápida resultante, combinada con zonas convectivas profundas en estrellas de tipo tardío, es un ingrediente clave para la generación de campos magnéticos intensos y, por ende, una actividad de manchas estelares significativa [Strassmeier, 2009].

- **Hallazgos de Tran et al. [2013]:** El estudio seminal de Tran et al. [2013], que sentó las bases para la interpretación de los O-C anticorrelacionados como un efecto de manchas en binarias de Kepler, encontró que la gran mayoría de los sistemas que exhibían esta firma poseían períodos orbitales significativamente cortos. Específicamente, su Tabla 1 muestra que de los ~ 390 sistemas con O-C anticorrelacionados, 306 (aproximadamente 78 %) tenían períodos $P \leq 0,5$ días, y 355 (aproximadamente 91 %) tenían períodos $P \leq 1$ día. El fenómeno disminuía drásticamente para períodos más largos. Aunque el pico de prevalencia para la anticorrelación “clásica” por manchas está en $P \lesssim 0,5 - 0,6$ días, extender el umbral a 1 día permite incluir una porción mayor de estas binarias cercanas activas, donde la física de la sincronización y los efectos de manchas aún pueden ser relevantes, aunque quizás con características ligeramente diferentes o menor dominancia.
- **Distinción de Regímenes Físicos:** Un período de 1 día a menudo marca una transición en la naturaleza de los sistemas binarios. Por debajo de este valor, predominan las interacciones fuertes y los efectos de evolución de binarias cercanas. Por encima, es más común encontrar binarias separadas donde las estrellas evolucionan de manera más independiente, o sistemas semidesprendidos con períodos más largos donde la transferencia de masa y la presencia de terceros cuerpos pueden ser los principales moduladores de los O-C.

Por lo tanto, el desglose de cada clase predicha en subgrupos con períodos orbitales menores o iguales a 1 día y mayores a 1 día permite investigar si los patrones O-C identificados por el modelo CNN se correlacionan con estos diferentes regímenes físicos esperados. Dentro de cada uno de estos subgrupos de período, se analizó la distribución de los `binary_type` para contextualizar aún más las predicciones del modelo y explorar posibles correlaciones entre la morfología O-C predicha, el período orbital y la naturaleza física conocida de los sistemas. A continuación, se presentan los resultados detallados para cada clase.

El modelo ResNet-50, entrenado con el conjunto de datos sintéticos multiclase (Sección 6.3.1),

se aplicó a las representaciones visuales de las curvas O-C de los **1438** sistemas binarios observacionales de Kepler procesados. A continuación, se presenta la distribución de estos sistemas entre las seis clases de patrones O-C predichas por el modelo: **C0_Anticorrelated**, **C1_Correlated_Oscillatory_LTTE**, **C2_Correlated_Parabolic**, **C3_Flat_Noisy**, **C4_Mixed_Complex**, y **C5_Abrupt_Change**. Cada clase se analiza en conjunto con el período orbital (utilizando un umbral de 1 día) y el tipo de variabilidad o naturaleza estelar (**binary_type**) conocido.

7.3. Clase C0: Patrones Anticorrelacionados (Indicativos de Manchas Estelares)

Un total de **230** sistemas fueron clasificados en la categoría **C0_Anticorrelated** (Tabla 2). Esta clase se caracteriza por un movimiento opuesto en las variaciones O-C de los eclipses primario y secundario, una firma robusta de la modulación fotométrica por manchas estelares que migran diferencialmente en la superficie de una de las componentes [Tran et al., 2013, Balaji et al., 2015].

Interpretación para C0: De los sistemas en **C0**, 97 (36 %) poseen períodos $P \leq 1$ día. En este régimen, la predominancia de **EclBin** (82) y la notable presencia de 12 **RSCVnV*** son consistentes con la interpretación de manchas en binarias activas, muchas de las cuales son de contacto o cercanas [ver e.g., Strassmeier, 2009, Hall and Busby, 1990]. La clasificación de la mayoría de los sistemas (129) con $P > 1$ día en esta categoría es un hallazgo significativo. Aunque la interpretación canónica de la anticorrelación O-C por manchas es más robusta para períodos cortos [Tran et al., 2013], el modelo identifica esta morfología también en sistemas de período más largo. Estos podrían incluir binarias separadas o semidesprendidas con componentes activas (**RSCVnV***, **SB***) donde los efectos de manchas aún influyen en los tiempos de eclipse, o donde la anticorrelación podría tener un origen diferente o más complejo; se puede observar algunos de los sistemas clasificados en la figura 10.

Diagramas O-C de Sistemas Binarios




Figura 10: Diagramas O-C de los sistemas clasificados por el modelo como C0 (KIC: 8111387,9649493,6286402,11402381 de izquierda a derecha, de arriba a abajo)

Tabla 2: Distribución de tipos binarios y período para la clase **C0_Anticorrelated**.

Período Orbital	Tipo Binario (binary_type)	N° Sist.
$P \leq 1$ día	EclBin	82
	No data	1
	RSCVnV*	12
	delSctV*	2
	Subtotal ($P \leq 1$ día)	97
$P > 1$ día	**	3
	ChemPec*	1
	EclBin	104
	EmLine*	2
	RGB*	2
	RSCVnV*	3
	RotV*	1
	SB*	8
	SXPheV*	1
	Star	1
	delSctV*	3
	Subtotal ($P > 1$ día)	129
Período Desconocido/NaN		4
Total en Clase C0		230

7.4. Clase C1: Patrones Correlacionados Oscilatorios (Indicativos de LTTE)

El modelo asignó **140** sistemas a **C1_Correlated_Oscillatory_LTTE** (Tabla 3). Este patrón es el indicador principal del Light Travel Time Effect (LTTE) debido a un tercer cuerpo [Irwin, 1952, Conroy et al., 2014].

Interpretación para C1: La mayoría tiene períodos internos $P > 1$ día, lo cual es esperable para jerarquías triples. Un número significativo (41 sistemas) con $P \leq 1$ día también muestra esta firma, sugiriendo sistemas triples compactos, cuya formación puede ser facilitada por mecanismos como el de Kozai-Lidov [Kozai, 1962, Lidov, 1962, Fabrycky and Tremaine, 2007]. La presencia de estrellas pulsantes (**RRLyrae**, **delSctV***) podría indicar que son miembros de sistemas triples, o que sus variaciones intrínsecas de período de pulsación (e.g., efecto Blazhko en RR Lyraes, Szabó, 2010) generan patrones O-C que el modelo confunde con LTTE, se puede observar algunos de los

Tabla 3: Distribución de tipos binarios y período para la clase **C1_Correlated_Oscillatory_LTTE**.

Período Orbital	Tipo Binario (binary_type)	N° Sist.
$P \leq 1$ día	EclBin	35
	RRLyrae	1
	RSCVnV*	1
	SB*	1
	Star	1
	delSctV*	2
Subtotal ($P \leq 1$ día)		41
$P > 1$ día	**	1
	BYDraV*	2
	ChemPec*	1
	EclBin	79
	RGB*	2
	RSCVnV*	2
	RotV*	2
	SB*	6
	delSctV*	1
Subtotal ($P > 1$ día)		96
Período Desconocido/NaN		3
Total en Clase C1		140

sistemas clasificados en 11.

7.5. Clase C2: Patrones Correlacionados Parabólicos (Indicativos de Cambio Secular de Período)

Un total de 79 sistemas fueron clasificados como **C2_Correlated_Parabolic** (Tabla 4). Una tendencia parabólica es el indicador clásico de un cambio secular en el período orbital, usualmente atribuido a transferencia de masa o pérdida de momento angular [Hilditch, 2001, Qian, 2001].

Interpretación para C2: La mayoría tiene períodos $P \leq 1$ día, sugiriendo procesos de cambio de período activos en binarias cercanas. La presencia de 10 **HotSubdwarf** es consistente con fases de transferencia de masa intensa [e.g., Heber, 2016]. Las **RSCVnV*** aquí podrían estar experi-

Diagramas O-C de Sistemas Binarios




Figura 11: Diagramas O-C de los sistemas clasificados por el modelo como C1 (KIC: 7362751,8043961,8386865,9912977 de izquierda a derecha, de arriba a abajo)

Tabla 4: Distribución de tipos binarios y período para la clase **C2_Correlated_Parabolic**.

Período Orbital	Tipo Binario (binary_type)	N° Sist.
$P \leq 1$ día	**	1
	EclBin	32
	HotSubdwarf	10
	RRLyrae	1
	RSCVnV*	1
	SB*	1
	delSctV*	1
	Subtotal ($P \leq 1$ día)	47
$P > 1$ día	EclBin	25
	RSCVnV*	3
	SB*	2
	delSctV*	2
	Subtotal ($P > 1$ día)	32
Total en Clase C2		79

mentando pérdida de momento angular vía vientos magnetizados [Schrijver and Zwaan, 2000] o efectos de Applegate de muy largo plazo [Applegate, 1992]., se puede observar algunos de los sistemas clasificados en la figura 12.




Figura 12: Diagramas O-C de los sistemas clasificados por el modelo como C2 (KIC: 12055014,11825204,4074532,9402652 de izquierda a derecha, de arriba a abajo)

7.6. Clase C3: Patrones Planos o Ruidosos (Sin Señal O-C Clara)

La clase **C3_Flat_Noisy** es la más numerosa con 259 sistemas (Tabla 5), indicando estabilidad orbital o variaciones O-C por debajo del umbral de detección.

Interpretación para C3: La diversidad de tipos estelares aquí sugiere que para muchos sistemas, las variaciones O-C son mínimas. La presencia de estrellas activas como **RSCVnV*** o pulsantes como **delSctV*** podría indicar fases de baja actividad O-C o que sus variaciones intrínsecas no

Tabla 5: Distribución de tipos binarios y período para la clase **C3_Flat_Noisy**.

Período Orbital	Tipo Binario (binary_type)	Nº Sist.
$P \leq 1$ día	**	2
	EclBin	153
	EmLine*	1
	HorBranch*	1
	HotSubdwarf	4
	RGB*	2
	RRLyrae	1
	RSCVnV*	9
	RotV*	2
	SB*	3
	Star	8
	Variable*	1
	WhiteDwarf	1
	delSctV*	9
	Subtotal ($P \leq 1$ día)	197
$P > 1$ día	**	2
	EclBin	50
	EllipVar	1
	RotV*	1
	SB*	5
	Star	1
	delSctV*	1
	Subtotal ($P > 1$ día)	61
Período Desconocido/NaN		1
Total en Clase C3		259

producen los patrones morfológicos de las otras clases, se puede observar algunos de los sistemas clasificados en la figura 13.




Figura 13: Diagramas O-C de los sistemas clasificados por el modelo como C3 (KIC: 5259926,8564672,7769072,6699679 de izquierda a derecha, de arriba a abajo)

7.7. Clase C4: Patrones Mixtos o Complejos

Con **581** sistemas, **C4_Mixed_Complex** es la segunda clase más poblada (Tabla 6), indicando que la superposición de múltiples efectos O-C es un escenario común.

Interpretación para C4: La vasta mayoría ocurre en binarias con $P \leq 1$ día. Esto sugiere que muchas binarias cercanas experimentan simultáneamente, por ejemplo, actividad de manchas (componente anticorrelacionada) y LTTE o un cambio secular (componente correlacionada). La alta

Tabla 6: Distribución de tipos binarios y período para la clase **C4_Mixed_Complex**.

Período Orbital	Tipo Binario (binary_type)	Nº Sist.
$P \leq 1$ día	**	3
	BYDraV	3
	EclBin	384
	Eruptive*	2
	RRLyrae	1
	RSCVnV*	29
	SB*	3
	delSctV*	11
	Subtotal ($P \leq 1$ día)	436
$P > 1$ día	**	5
	ChemPec*	2
	EclBin	115
	HorBranch*	1
	RGB	1
	RSCVnV*	4
	RotV*	1
	SB*	10
	star	1
	Subtotal ($P > 1$ día)	140
Período Desconocido/NaN		5
Total en Clase C4		581

concentración de 29 **RSCVnV*** en el subgrupo de período corto apoya esta interpretación, se puede observar algunos de los sistemas clasificados en la imagen 14.




Figura 14: Diagramas O-C de los sistemas clasificados por el modelo como C4 (KIC: 4945588,5951553,11404758,7871200 de izquierda a derecha, de arriba a abajo)

7.8. Clase C5: Cambios Abruptos de Período

Finalmente, **148** sistemas fueron clasificados en **C5_Abrupt_Change** (Tabla 7), caracterizada por discontinuidades súbitas.

Interpretación para C5: Una gran proporción ocurre en sistemas con $P \leq 1$ día. Estos cambios podrían deberse a transferencia de masa episódica o reconfiguraciones magnéticas en estrellas activas (4 **RSCVnV*** en período corto). La literatura sobre cambios abruptos de período en binarias es extensa, a menudo invocando transferencia de masa o pérdida de momento angular magnético

Tabla 7: Distribución de tipos binarios y período para la clase **C5_Abrupt_Change**.

Período Orbital	Tipo Binario (binary_type)	N° Sist.
$P \leq 1$ día	Blend*	1
	EclBin	93
	BlueStraggler	1
	RRLyrae	1
	RSCVnV*	4
	RotV*	1
	SB*	1
	delSctV*	4
	Subtotal ($P \leq 1$ día)	106
$P > 1$ día	**	2
	EclBin	36
	SB*	2
	RGB*	1
	delSctV*	1
	Subtotal ($P > 1$ día)	42
Período Desconocido/NaN		0
Total en Clase C5		148

[e.g., [Kreiner et al., 2001](#)]. Se puede observar algunos de los sistemas clasificados por el modelo en la figura 15

7.9. Comparación con Clasificaciones Previas: El Caso de los Sistemas de Balaji et al. (2014)

Para contextualizar y evaluar adicionalmente las predicciones de nuestro modelo CNN en datos reales, se realizó una comparación con un conjunto de sistemas previamente identificados en la literatura por su comportamiento O-C característico. Específicamente, se utilizó la lista de 414 sistemas binarios de Kepler que [Balaji et al. \[2015\]](#) analizaron, los cuales fueron originalmente seleccionados por [Tran et al. \[2013\]](#) debido a que sus diagramas O-C exhibían una naturaleza predominantemente anticorrelacionada, interpretada como un indicativo de la actividad de manchas estelares.

Diagramas O-C de Sistemas Binarios




Figura 15: Diagramas O-C de los sistemas clasificados por el modelo como C5 (KIC: 5685072,9533706,9541127,9164694 de izquierda a derecha, de arriba a abajo)

De los 414 KICs en la lista de [Balaji et al. \[2015\]](#), se encontraron **381** dentro de nuestro conjunto de datos Kepler procesados y clasificados por el modelo ResNet-50. La Tabla 8 muestra cómo nuestro modelo de seis clases distribuyó estos 381 sistemas.

Tabla 8: Clasificación por el modelo ResNet-50 de los 381 sistemas Kepler también analizados por [Balaji et al. \[2015\]](#) y considerados por ellos como exhibidores de O-C anticorrelacionado (indicativo de manchas).

Clase Predicha por ResNet-50	N° Sistemas	Porcentaje (%)
C0_Anticorrelated	61	16,01
C1_Correlated_Oscillatory_LTTE	5	1,31
C2_Correlated_Parabolic	2	0,52
C3_Flat_Noisy	18	4,72
C4_Mixed_Complex	267	70,08
C5_Abrupt_Change	28	7,35
Total de Sistemas de Balaji Analizados	381	100.00

El resultado más notable es que la vasta mayoría (267 sistemas, o $\sim 70\%$) de estos objetos, identificados por [Balaji et al. \[2015\]](#) por su firma de manchas, fueron clasificados por nuestro modelo como **C4_Mixed_Complex**. Esto sugiere que, si bien estos sistemas probablemente poseen la componente anticorrelacionada debida a manchas que dichos autores rastrearon, nuestro modelo CNN, al analizar la morfología completa de la curva O-C, detecta simultáneamente la presencia de otros patrones o complejidades (e.g., tendencias de largo plazo de tipo LTTE o parabólicas superpuestas). Este hallazgo es consistente con la observación de que el preprocesamiento mediante suavizado, aplicado a los datos reales antes de la clasificación por la CNN, puede ayudar a revelar señales secundarias que estaban previamente enmascaradas por el ruido.

Un 16 % (61 sistemas) fueron clasificados como **C0_Anticorrelated**, lo que representa los casos donde, según nuestro modelo, el patrón de manchas es el más puro y dominante. Un número menor de estos sistemas fue asignado a **C3_Flat_Noisy** (18 sistemas, $\sim 4.7\%$), lo que podría indicar que la señal anticorrelacionada en estos casos era de muy baja amplitud o fue atenuada por el suavizado. La clasificación de 28 sistemas ($\sim 7.3\%$) como **C5_Abrupt_Change** es también interesante, sugiriendo que la actividad de manchas en algunos sistemas podría estar asociada o coexistir con cambios de período más dinámicos o erráticos que el modelo ResNet-50 interpreta

como saltos. Las pocas clasificaciones en **C1** y **C2** indican que, para la mayoría de estos sistemas seleccionados por Balaji et al., los patrones correlacionados no son la característica dominante.

Esta comparación subraya que, si bien existe una concordancia general en la identificación de actividad (ya que la clase **C4** a menudo implica una componente de manchas), el enfoque multiclase de la CNN puede ofrecer un desglose más fino de la naturaleza de las variaciones O-C, distinguiendo entre un efecto de manchas "puro" y casos donde este coexiste o es modificado por otros fenómenos físicos.

8. Discusión

8.1. Limitaciones del Enfoque Basado en Correlaciones Globales y Agrupamiento No Supervisado

La aplicación de técnicas de reducción de dimensionalidad (PCA, t-SNE y UMAP, ver Figura 5) a los tres coeficientes de correlación (Pearson, Spearman y Kendall) reveló una estructura inherente en los datos, permitiendo visualizar ciertas agrupaciones. En particular, las proyecciones de t-SNE y UMAP sugirieron la posibilidad de separar, a grandes rasgos, sistemas con comportamientos O-C predominantemente correlacionados de aquellos predominantemente anticorrelacionados.

Posteriormente, se aplicó el algoritmo de agrupamiento DBSCAN a estas representaciones de baja dimensión (así como a los coeficientes de correlación originales) para intentar identificar automáticamente grupos de sistemas con características de correlación similares. Los resultados de este agrupamiento (vease 6) indicaron que, si bien DBSCAN podía identificar algunos clústeres basados en la densidad de los puntos en el espacio de características de correlación, estos clústeres no siempre tenían una interpretación física directa o una correspondencia unívoca con la diversidad morfológica completa observada en las curvas O-C.

Por ejemplo, aunque se podían formar grupos que mayoritariamente contenían sistemas anticorrelacionados o correlacionados, la variabilidad dentro de estos grupos seguía siendo alta. Sistemas con patrones temporales visualmente distintos (e.g., una oscilación sinusoidal correlacionada versus una tendencia parabólica correlacionada, o diferentes tipos de comportamiento anticorrelacionado) podían terminar en el mismo clúster si sus coeficientes de correlación globales eran similares. Inversamente, sistemas con la misma fenomenología física subyacente pero con diferentes niveles de ruido o amplitudes en sus curvas O-C (lo que puede afectar los valores de los coeficientes de correlación) podían ser asignados a clústeres diferentes o ser marcados como ruido

por DBSCAN.

Esta exploración subraya una limitación inherente al depender únicamente de índices de correlación globales:

- **Pérdida de Información Temporal y Morfológica:** Los coeficientes de correlación resumen la relación entre dos series en un único valor numérico, perdiendo información crucial sobre la forma específica de las curvas, las escalas de tiempo de las variaciones, la presencia de múltiples componentes de señal (como en los casos mixtos), o la naturaleza de eventos transitorios (como cambios abruptos).
- **Sensibilidad al Ruido y Amplitud:** Aunque los coeficientes no paramétricos como Spearman y Kendall son menos sensibles a outliers que Pearson, todos pueden verse afectados por el nivel de ruido general y la amplitud relativa de las señales, lo que puede llevar a que sistemas físicamente similares presenten coeficientes diferentes.
- **Naturaleza No Supervisada del Agrupamiento:** Los algoritmos como DBSCAN identifican estructura basada en la proximidad en el espacio de características proporcionado, sin conocimiento previo de las "clases" físicas o morfológicas que se buscan. Si las características no son suficientemente discriminatorias, los clústeres resultantes pueden no ser significativos para la tarea de clasificación deseada.

8.2. Interpretación de las Poblaciones Clasificadas y Consistencia Física

La aplicación del modelo ResNet-50 a los datos observacionales de Kepler ha resultado en la asignación de 1437 sistemas a seis categorías morfológicas de patrones O-C. El análisis de estas poblaciones, cruzado con información externa como el período orbital y el `binary_type`, permite una interpretación astrofísica preliminar y una evaluación de la coherencia de las clasificaciones

del modelo.

Una observación clave es la alta prevalencia de sistemas clasificados como **C4_Mixed_Complex** (581 sistemas), especialmente aquellos con períodos orbitales $P \leq 1$ día (436 sistemas). Este hallazgo sugiere que la superposición de múltiples mecanismos físicos que afectan los tiempos de eclipse (e.g., actividad de manchas y la presencia de un tercer compañero) es un escenario común, particularmente en binarias cercanas y de contacto. La notable concentración de estrellas **RSCVnV*** dentro de esta clase (17 en período corto, 3 en período largo) apoya esta interpretación, ya que estos sistemas son conocidos tanto por su intensa actividad magnética superficial como por una alta incidencia de multiplicidad. Nuestro modelo parece ser capaz de identificar estas señales combinadas que podrían ser difíciles de desenredar mediante inspección visual o con métricas simples.

La clase **C0_Anticorrelated**, identificada con la firma de manchas estelares, contiene 230 sistemas. De manera consistente con los trabajos de [Tran et al. \[2013\]](#) y [Balaji et al. \[2015\]](#), una fracción importante (97 sistemas) se encuentra en el régimen de período corto ($P \leq 1$ día) e incluye una población significativa de tipos estelares activos (**RSCVnV***, **BYDraV***). Sin embargo, el hallazgo de 129 sistemas **C0** con $P > 1$ día es intrigante. Si bien la interpretación directa como efecto de manchas es menos robusta para estos sistemas más separados, la clasificación por la CNN indica una similitud morfológica con el patrón canónico. Estos podrían representar binarias de período más largo con una o ambas componentes exhibiendo actividad magnética significativa, o casos donde la anticorrelación tiene un origen aún no completamente comprendido. La comparación con la lista de sistemas de [Balaji et al. \[2015\]](#) (Sección 7.9) mostró que, si bien nuestro modelo clasifica una porción como **C0**, muchos de los sistemas que ellos identificaron por anticorrelación caen en nuestra clase **C4**, reforzando la idea de complejidad superpuesta.

Los sistemas clasificados como **C1_Correlated_Oscillatory_LTTE** (140 sistemas) y **C2_Correlated_Parabolic** (79 sistemas) representan poblaciones donde las perturbaciones orbi-

tales globales (terceros cuerpos o cambios seculares de período, respectivamente) parecen dominar el diagrama O-C. La distribución de estos sistemas a través de un amplio rango de períodos orbitales es esperable. La presencia de estrellas pulsantes (**RRLyrae**, **delSctV***) en estas categorías (especialmente en **C1**) requiere una consideración cuidadosa, ya que sus variaciones intrínsecas de período de pulsación podrían, en algunos casos, imitar morfológicamente las señales de LTTE o cambios seculares para el clasificador visual.

La clase más numerosa, **C3_Flat_Noisy** (259 sistemas), probablemente agrupa sistemas genuinamente estables en la escala de tiempo de Kepler, así como aquellos donde cualquier variación física está por debajo del umbral de detección del ruido fotométrico o de la sensibilidad de nuestro modelo para extraer patrones débiles. Finalmente, los 209 sistemas en **C5_Abrupt_Change** sugieren que los cambios de período discretos son un fenómeno relativamente común, particularmente en sistemas de período corto, y su asociación con tipos estelares activos como **RSCVnV*** podría indicar una conexión con eventos energéticos de origen magnético o episodios de transferencia de masa.

En general, la clasificación proporcionada por el modelo CNN ofrece un primer censo detallado de la diversidad de comportamientos O-C. Si bien el rendimiento en datos sintéticos fue excepcional, la interpretación de las clases para datos reales debe considerar la complejidad inherente de los fenómenos astrofísicos y la posibilidad de que múltiples procesos contribuyan a la morfología observada. Los sistemas identificados, especialmente aquellos en las clases **C1**, **C4** y **C5**, así como los casos **C0** de período largo, constituyen un conjunto valioso de candidatos para estudios de seguimiento y modelado individualizado.

8.3. Correlación entre Patrones O-C Predichos y Tipos de Sistemas Binarios

El análisis de la distribución de los tipos de sistemas binarios (`binary_type`) a través de las seis clases de patrones O-C predichas (Tabla 9) revela tendencias generales consistentes con las expectativas físicas y resalta la complejidad inherente a estos sistemas.

Como era de esperarse, la categoría genérica **EclBin** (Binaria Eclipsante) domina numéricamente en todas las clases predichas, lo cual es una consecuencia natural de que el estudio se centra en variaciones de tiempos de eclipse. Más reveladora es la distribución de tipos estelares con características conocidas de actividad o evolución. Los sistemas conocidos por su actividad magnética, como las variables **RSCVnV***, muestran una clara preferencia por las clases **C0_Anticorrelated** (indicativa de manchas), **C4_Mixed_Complex** (sugiriendo manchas más otros efectos), y **C5_Abrupt_Change** (posiblemente cambios de período inducidos por actividad magnética intensa). Esta asociación valida la capacidad del modelo para identificar patrones O-C relacionados con la actividad estelar.

La clase **C1_Correlated_Oscillatory_LTTE**, interpretada como la firma de terceros cuerpos, contiene, además de **EclBin**, una mezcla de otros tipos, incluyendo binarias espectroscópicas (**SB***) y algunas estrellas pulsantes. Esto sugiere que la multiplicidad es un fenómeno extendido y que el efecto LTTE puede ser el modulador O-C dominante independientemente de otras características intrínsecas de la binaria interna, aunque la presencia de pulsantes requiere una interpretación cautelosa de posibles confusiones con sus propios ciclos de variación de período.

Por otro lado, la clase **C3_Flat_Noisy**, que es significativamente poblada, agrupa una gran diversidad de tipos estelares. Esto indica que muchos sistemas binarios, independientemente de su clasificación específica, exhiben una notable estabilidad orbital o variaciones O-C por debajo del umbral de detección de nuestro método durante el periodo de observación de Kepler.

La clase **C4_Mixed_Complex** emerge como la más numerosa en general (según tus últimos datos), lo que subraya que la superposición de múltiples mecanismos físicos afectando los diagramas O-C es un escenario frecuente, más que la excepción. Esto es particularmente cierto para sistemas de período corto, donde las interacciones son más intensas.

En conjunto, si bien no existe una correspondencia uno a uno estricta entre un ‘binary_type’ específico y una única clase O-C (a excepción de la fuerte tendencia de las estrellas activas hacia C0, C4 y C5), la distribución observada es físicamente coherente. Demuestra que, mientras el modelo CNN es eficaz en agrupar sistemas por la morfología de sus variaciones O-C, la interpretación final de la física subyacente en un sistema individual se beneficia enormemente de la consideración conjunta del patrón O-C, el período orbital y la naturaleza conocida del sistema.

Tabla 9: Distribución de tipos de sistemas binarios (**binary_type**) a través de las seis clases de patrones O-C predichas por el modelo CNN. Los números indican la cantidad de sistemas de cada **binary_type** asignados a cada clase O-C.

Tipo Binario (binary_type)	C0 (Anti)	C1 (LTTE)	C2 (Parab)	C3 (Ruido)	C4 (Mixto)	C5 (Abr.)	Total por Tipo
EclBin	220	93	117	298	291	178	1197
RSCVnV*	13	2	4	13	20	16	68
SB*	12	5	4	12	5	4	42
delSctV*	5	3	4	14	8	3	37
**	3	3	3	4	3	3	19
Desconocido/NaN	6	3	0	3	2	0	14
Star	1	1	0	9	0	1	12
RotV*	0	3	0	5	0	0	8
RGB*	3	3	0	2	0	0	8
BYDraV*	2	2	0	0	0	1	5

(Continuación en la siguiente página)

Tabla 9 – Continuación de la página anterior

Tipo Binario	C0	C1	C2	C3	C4	C5	Total
(binary_type)	(Anti)	(LTTE)	(Parab)	(Ruido)	(Mixto)	(Abr.)	por Tipo
RRLyrae	0	1	2	0	1	1	5
HotSubdwarf	0	0	2	3	0	0	5
ChemPec*	3	1	0	0	0	0	4
EmLine*	2	0	0	1	0	0	3
HorBranch*	0	0	0	1	0	1	2
Eruptive*	1	0	0	0	0	1	2
No data	1	0	0	0	0	0	1
BlueStraggler	0	0	0	1	0	0	1
Blend	0	0	0	1	0	0	1
SXPheV*	0	0	0	1	0	0	1
EllipVar	0	0	0	1	0	0	1
Variable*	0	0	0	1	0	0	1
WhiteDwarf	0	0	0	1	0	0	1

9. conclusión

La caracterización de los fenómenos físicos que modulan los períodos orbitales o alteran los tiempos de los eclipses en sistemas binarios es fundamental para nuestra comprensión de la dinámica estelar y la actividad magnética. Los diagramas de variación de tiempos de eclipse (O-C) encapsulan esta información, pero su análisis en grandes catálogos astronómicos requiere herramientas eficientes y robustas. Este trabajo de tesis abordó este desafío mediante el desarrollo e implementación de un método basado en aprendizaje profundo para la clasificación automática de patrones morfológicos en diagramas O-C.

El enfoque principal consistió en entrenar una Red Neuronal Convolutiva (CNN) basada en la arquitectura ResNet-50 sobre representaciones visuales minimalistas de las curvas O-C. Para ello, se generó un extenso conjunto de datos sintéticos (60,000 imágenes) que simula seis categorías principales de comportamiento O-C: (C0) anticorrelacionado por manchas estelares, (C1) correlacionado oscilatorio por LTTE, (C2) correlacionado parabólico por cambio secular, (C3) plano/ruidoso, (C4) mixto/complejo, y (C5) cambios abruptos.

Los resultados principales de este estudio se resumen a continuación:

1. **Excelente Capacidad de Discriminación del Modelo CNN en Datos Sintéticos:** El modelo ResNet-50 modificado demostró una capacidad sobresaliente para clasificar los patrones O-C sintéticos, alcanzando una precisión superior al 99 % en el conjunto de prueba. Esto confirma que la arquitectura es adecuada para aprender las características morfológicas distintivas de las seis clases definidas a partir de sus representaciones visuales. Es importante notar que este alto rendimiento en datos sintéticos valida la capacidad del modelo para aprender los patrones ideales, aunque la generalización a datos reales, con su inherente complejidad y ruido, constituye un desafío adicional relacionado con el desajuste de dominio.

2. **Aplicación Exitosa y Caracterización Sistemática en Datos de Kepler:** El modelo entrenado se aplicó exitosamente a un conjunto de **1437** sistemas binarios observacionales del catálogo Kepler. Esta aplicación permitió asignar cada sistema a una de las seis categorías de patrones O-C, facilitando una primera caracterización sistemática y automatizada de la naturaleza de las variaciones O-C en esta extensa muestra.
3. **Identificación de Poblaciones con Implicancias Astrofísicas Relevantes:** El análisis de las clases predichas para los datos de Kepler, en conjunto con información sobre el período orbital y el tipo de binaria (`binary_type`), reveló distribuciones y correlaciones de interés astrofísico. Destaca la identificación de **230** sistemas en la clase **C0_Anticorrelated** (manchas), con una notable presencia de estrellas activas (**RSCVnV***) y una intrigante población de sistemas con $P > 1$ día. Se identificaron **140** candidatos a sistemas triples (clase **C1_Correlated_Oscillatory_LTTE**). La clase **C4_Mixed_Complex** emergió como la más poblada, especialmente en sistemas de período corto, subrayando la frecuente coexistencia de múltiples mecanismos físicos (e.g., manchas y cambio secular). Adicionalmente, se identificaron poblaciones significativas experimentando cambios de período seculares (**C2_Correlated_Parabolic**) y súbitos (**C5_Abrupt_Change**).
4. **Superioridad del Enfoque CNN sobre Métodos Basados en Correlaciones Globales:** Un análisis exploratorio previo, utilizando únicamente coeficientes de correlación y algoritmos de agrupamiento no supervisado, demostró ser insuficiente para una clasificación fina y robusta en las seis categorías de interés. Esto justificó la necesidad y validó la adopción del enfoque de aprendizaje profundo basado en CNNs, que pueden capturar la información morfológica completa de las curvas.

La **contribución novedosa principal** de este trabajo radica en la aplicación exitosa y el análisis detallado de una arquitectura CNN profunda (ResNet-50) para la clasificación multiclase de una amplia gama de patrones morfológicos en diagramas O-C. Este enfoque, utilizando imágenes

generadas a partir de datos tanto sintéticos como observacionales, supera las limitaciones de los análisis tradicionales basados en características globales simples y ofrece una herramienta potente y escalable para la caracterización de grandes conjuntos de datos de variaciones de tiempo de eclipse, como los provenientes de misiones como Kepler y TESS. El cruce de las predicciones con parámetros físicos de los sistemas ha proporcionado nuevas perspectivas sobre la prevalencia y coexistencia de diferentes fenómenos físicos en sistemas binarios.

No obstante, este estudio presenta limitaciones. La clasificación se fundamenta en la morfología visual de las curvas O-C. Aunque las clases sintéticas fueron diseñadas para representar fenómenos físicos específicos, la interpretación de las predicciones para datos reales, especialmente para patrones complejos (clase **C4**) o en regímenes de período donde múltiples mecanismos pueden producir formas visualmente similares, requiere cautela. La fidelidad y representatividad de los datos sintéticos respecto a la complejidad del universo real son cruciales y siempre pueden ser un área de mejora.

Como **trabajos futuros**, se podrían explorar diversas líneas de investigación para expandir y refinar los hallazgos de esta tesis:

- Mejorar la generación de datos sintéticos, incorporando una mayor diversidad de formas dentro de cada clase y un modelado más realista del ruido y artefactos, especialmente para la clase **C4_Mixed_Complex**.
- Aplicar el modelo entrenado (o reentrenarlo si es necesario) a datos O-C de otras misiones astronómicas (e.g., TESS, Gaia, sondeos terrestres) para investigar la universalidad de los patrones y las distribuciones de clases.
- Realizar estudios de seguimiento detallados (e.g., análisis espectroscópico, modelado fotométrico y de O-C individualizado) para una submuestra de los sistemas clasificados, con el fin de confirmar la naturaleza física de las variaciones O-C predichas, particularmente pa-

ra los candidatos a LTTE, los casos mixtos, y los sistemas con cambios abruptos o patrones anticorrelacionados en períodos largos.

- Investigar el uso de arquitecturas de Deep Learning alternativas que procesen directamente las series temporales O-C como secuencias (e.g., Redes Neuronales Recurrentes, Transformers, 1D-CNNs) y comparar su rendimiento y capacidad interpretativa con el enfoque actual basado en imágenes.
- Profundizar en el análisis de los sistemas con $P > 1$ día clasificados como **C0_Anticorrelated** para discernir la naturaleza de la anticorrelación en estos sistemas más separados.

En definitiva, esta tesis ha demostrado el significativo potencial del aprendizaje profundo, y específicamente las CNNs, como una herramienta eficaz y escalable para la clasificación de patrones en diagramas O-C. Este enfoque facilita la identificación de fenómenos astrofísicos de interés en grandes volúmenes de datos de sistemas binarios, abriendo nuevas vías para su estudio sistemático y detallado, y contribuyendo a una mejor comprensión de la rica dinámica presente en estos laboratorios cósmicos.

Referencias

- K. Tran, A. Levine, S. Rappaport, T. Borkovits, Sz. Csizmadia, and B. Kalomeni. The Anticorrelated Nature of the Primary and Secondary Eclipse Timing Variations for the Kepler Contact Binaries. , 774(1):81, September 2013. doi: 10.1088/0004-637X/774/1/81.
- Bhaskaran Balaji, Bryce Croll, Alan M. Levine, and Saul Rappaport. Tracking the stellar longitudes of starspots in short-period Kepler binaries. *Monthly Notices of the Royal Astronomical Society*, 448(1):429–444, mar 2015. ISSN 0035-8711. doi: 10.1093/mnras/stv031. URL <https://doi.org/10.1093/mnras/stv031>.
- Klaus G. Strassmeier. Starspots. *The Astronomy and Astrophysics Review*, 17(3):251–308, 2009. ISSN 1432-0754. doi: 10.1007/s00159-009-0020-6. URL <https://doi.org/10.1007/s00159-009-0020-6>.
- Svetlana V. Berdyugina. Starspots: A Key to the Stellar Dynamo. *Living Reviews in Solar Physics*, 2(1):8, December 2005. doi: 10.12942/lrsp-2005-8.
- Eugene N. Parker. *Cosmical Magnetic Fields: Their Origin and their Activity*. The International Series of Monographs on Physics. Clarendon Press; Oxford University Press, Oxford, New York, 1979.
- Douglas S. Hall and Michael R. Busby. A review of starspot models. In C. Ibanoglu, editor, *Active Close Binaries*, volume 319 of *NATO ASI Series C: Mathematical and Physical Sciences*, pages 377–398. Kluwer Academic Publishers, 1990. doi: 10.1007/978-94-009-0470-7_32.
- J. C. Morales, I. Ribas, and C. Jordi. The effect of activity on stellar temperatures and radii. , 489 (3):L39–L42, October 2008. doi: 10.1051/0004-6361:200810555.
- Keivan G. Stassun, Kaitlin M. Kratter, Aleks Scholz, and Trent J. Dupuy. On the Incompatibility of Magnetic Activity and M-dwarf Radius Inflation. , 754(1):47, July 2012. doi: 10.1088/0004-637X/754/1/47.

William J. Borucki, David Koch, Gibor Basri, Natalie Batalha, Timothy Brown, Douglas Caldwell, John Caldwell, Jørgen Christensen-Dalsgaard, William D. Cochran, Edna DeVore, Edward W. Dunham, Andrea K. Dupree, Thomas N. Gautier, John C. Geary, Ronald Gilliland, Alan Gould, Steve B. Howell, Jon M. Jenkins, Yoji Kondo, David W. Latham, Geoffrey W. Marcy, Søren Meibom, Hans Kjeldsen, Jack J. Lissauer, David G. Monet, David Morrison, Dimitar Sasselov, Jill Tarter, Alan Boss, Don Brownlee, Tobias Owen, Derek Buzasi, David Charbonneau, Lorraine Doyle, Jonathan Fortney, Eric B. Ford, Matthew J. Holman, Sara Seager, Jason H. Steffen, William F. Welsh, Jason Rowe, Howard Anderson, Lars Buchhave, David Ciardi, Lucianne Walkowicz, William Sherry, Elliott Horch, Howard Isaacson, Mark E. Everett, Debra Fischer, Guillermo Torres, John Asher Johnson, Michael Endl, Phillip MacQueen, Stephen T. Bryson, Jessie Dotson, Michael Haas, Jeffery Kolodziejczak, Jeffrey Van Cleve, Hema Chandrasekaran, Joseph D. Twicken, Elisa V. Quintana, Bruce D. Clarke, Christopher Allen, Jie Li, Haley Wu, Peter Tenenbaum, Ekaterina Verner, Fred Bruhweiler, Jason W. Barnes, and Andrej Prsa. Kepler Planet-Detection Mission: Introduction and First Results. *Science*, 327(5968):977–980, February 2010. doi: 10.1126/science.1185402.

George R. Ricker, Joshua N. Winn, Roland Vanderspek, David W. Latham, Gáspár Á. Bakos, Jacob L. Bean, Zachory K. Berta-Thompson, Timothy M. Brown, Lars Buchhave, Nathaniel R. Butler, R. Paul Butler, William J. Chaplin, David Charbonneau, Jørgen Christensen-Dalsgaard, Mark Clampin, Drake Deming, John Doty, Nathan De Lee, Courtney Dressing, Edward W. Dunham, Michael Endl, François Fressin, Jian Ge, Thomas Henning, Matthew J. Holman, Andrew W. Howard, Shigeru Ida, Jon M. Jenkins, Garrett Jernigan, John Asher Johnson, Lisa Kaltenegger, Nobuyuki Kawai, Hans Kjeldsen, Gregory Laughlin, Alan M. Levine, Douglas Lin, Jack J. Lissauer, Phillip MacQueen, Geoffrey Marcy, Peter R. McCullough, Timothy D. Morton, Norio Narita, Martin Paegert, Enric Palle, Francesco Pepe, Joshua Pepper, Andreas Quirrenbach, Stephen A. Rinehart, Dimitar Sasselov, Bun’ei Sato, Sara Seager, Alessandro Sozzetti, Keivan G. Stassun, Peter Sullivan, Andrew Szentgyorgyi, Guillermo Torres, Stephane Udry, and Joel Villaseñor. Transiting Exoplanet Survey Satellite (TESS). *Journal of Astronomical Telescopes, Ins-*

- truments, and Systems*, 1(1):014003, January 2015. doi: 10.1117/1.JATIS.1.1.014003.
- Eric D. Feigelson and G. Jogesh Babu. *Modern Statistical Methods for Astronomy: With R Applications*. Cambridge University Press, 2012. doi: 10.1017/CBO9781139012473.
- Željko Ivezić, Andrew J. Connolly, Jacob T. VanderPlas, and Alexander Gray. *Statistics, Data Mining, and Machine Learning in Astronomy*. Princeton University Press, 2014.
- Pankaj Mehta, Marin Bukov, Ching-Hao Wang, Alexandre G. R. Day, Clon Richardson, Charles K. Fisher, and David J. Schwab. A high-bias, low-variance introduction to Machine Learning for physicists. *Physics Reports*, 810:1–124, July 2019. doi: 10.1016/j.physrep.2019.03.001.
- Gibor Basri, Lucianne M. Walkowicz, Natalie Batalha, Ronald L. Gilliland, Jon Jenkins, William J. Borucki, David Koch, Douglas Caldwell, Andrea K. Dupree, David W. Latham, Søren Meibom, Steve Howell, and Timothy Brown. Photometric Variability in Kepler Target Stars. I. General Properties and Flags for Exoplanet Candidate Confirmation. , 141(1):20, January 2011. doi: 10.1088/0004-6256/141/1/20.
- James R. A. Davenport, Andrew A. West, John J. Bochanski, Suzanne L. Hawley, Kevin R. Covey, Eric Gaidos, and Andrew W. Mann. The Kepler Spot Score: A new, robust metric of stellar photometric variability for quantifying ensemble stellar activity. , 788(1):17, May 2014. doi: 10.1088/0004-637X/788/1/17.
- C. A. L. Bailer-Jones, B. @ , M. Irwin, J.-F. Claeskens, S. @ , M. Fouesneau, N. Hambly, S. Roeser, and E. Schilbach. Classifying the Gaia spectrophotometric data. , 386(3):1163–1183, May 2008. doi: 10.1111/j.1365-2966.2008.13091.x.
- Christopher J. Shallue and Andrew Vanderburg. Identifying Exoplanets with Deep Learning: A Five-planet Resonant Chain around Kepler-80 and an Eighth Planet around Kepler-90. , 155(2): 94, February 2018. doi: 10.3847/1538-3881/aa9e09.
- F. Förster, G. Cabrera-Vives, E. Castillo-Navarrete, P. A. Estévez, P. Sánchez-Sáez, J. Arredondo, F. E. Bauer, Rodrigo Carrasco-Davis, Regis Cartier, Márcio Catelan, Sonia Duffau, Ignacio Elorte-

- gui, Susana Eyheramendy, Lluís Galbany, Santiago González-Gaitán, Alex Jeldes, Javier Jorquera, Viraj Karambelkar, Nicolás Medina, Ana María Muñoz-Arancibia, Glen Petitpas, Giuliano Pignata, Martín Pérez-Carrasco, Cristóbal Rojas-Marcos, Benjamín Sánchez, Pedro Sanhueza, Chris Smith, César Valenzuela, José Vicuña, and Misha Vinokur. The Automatic Learning for the Rapid Classification of Events (ALeRCE) Alert Broker. , 161(5):242, May 2021. doi: 10.3847/1538-3881/abe9bc.
- T. Cantat-Gaudin, C. Jordi, A. Vallenari, A. Bragaglia, L. Balaguer-Núñez, C. Soubiran, D. Bossini, A. Moitinho, A. Castro-Ginard, A. Krone-Martins, L. Casamiquela, R. Sordo, M. Fabrizio, and F. Figueras. A Gaia DR2 view of the open cluster population in the Milky Way. , 618:A93, November 2018. doi: 10.1051/0004-6361/201833475.
- Jeffrey D. Scargle. Studies in astronomical time series analysis. II - Statistical aspects of spectral analysis of unevenly spaced data. , 263:835–853, December 1982. doi: 10.1086/160554.
- The o-c diagram: Basic procedures. In Christiaan Sterken, editor, *The Light-Time Effect in Astrophysics: Causes and Cures of the O-C Diagram*, volume 335 of *ASP Conference Series*, pages 3–27. Astronomical Society of the Pacific, 2005.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, pages 770–778, 2016a. doi: 10.1109/CVPR.2016.90.
- Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. In *Proceedings of the IEEE*, volume 86, pages 2278–2324, 1998. doi: 10.1109/5.726791.
- John B. Irwin. The Determination of a Light-Time Orbit. , 116:211, May 1952. doi: 10.1086/145599.
- R. W. Hilditch. *An Introduction to Close Binary Stars*. Cambridge University Press, 2001. doi: 10.1017/CBO9780511536053.
- A. Duquennoy and M. Mayor. Multiplicity among solar-type stars in the solar neighbourhood. II. Distribution of the orbital elements in an unbiased sample. , 248:485–524, August 1991.

- H. Sana, S. E. de Mink, A. de Koter, N. Langer, C. J. Evans, M. Gieles, E. Gosset, R. G. Izzard, J.-B. Le Bouquin, and F. R. N. Schneider. Binary Interaction Dominates the Evolution of Massive Stars. *Science*, 337(6093):444–446, July 2012. doi: 10.1126/science.1223344.
- Peter Eggleton. *Evolutionary Processes in Binary and Multiple Stars*. Number 40 in Cambridge Astrophysics Series. Cambridge University Press, 2006. doi: 10.1017/CBO9780511800001.
- W. M. Smart. *Textbook on Spherical Astronomy*. Cambridge University Press, 6th edition, 1977.
- Peter H. Bodenheimer, Gregory P. Laughlin, Michał Różyczka, and Harold W. Yorke. *Principles of Star Formation*. Astronomy and Astrophysics Library. Springer, 2007. doi: 10.1007/978-3-540-33393-1.
- B. Paczyński. Evolutionary Processes in Close Binary Systems. , 9:183–208, 1971. doi: 10.1146/annurev.aa.09.090171.001151.
- Juhan Frank, Andrew King, and Derek J. Raine. *Accretion Power in Astrophysics*. Cambridge University Press, 3rd edition, 2002. doi: 10.1017/CBO9780511536091.
- L. B. Lucy. The Structure of Contact Binaries. , 153:877, September 1968. doi: 10.1086/149717.
- S. M. Rucinski. A Catalog of Contact and Semidetached Binaries. , 116(6):2998–3017, October 1998. doi: 10.1086/300624.
- Johannes Andersen. Accurate masses and radii of normal stars. , 3:91–126, 1991. doi: 10.1007/BF00873523.
- Guillermo Torres, Johannes Andersen, and Alvaro Giménez. Accurate masses and radii of normal stars: modern results and applications. , 18(1-2):67–126, February 2010. doi: 10.1007/s00159-009-0025-1.
- Piet Hut. Tidal evolution in close binary systems. , 99:126–140, March 1981.
- Eugene N. Parker. Hydromagnetic Dynamo Models. , 122:293, September 1955. doi: 10.1086/146087.

- Paul Charbonneau. Solar dynamo theory. In Alexander G. Kosovichev, Elisabete M. de Gouveia Dal Pino, and Yihua Yan, editors, *Solar and Stellar Dynamos: Observations and Experiments (IAU S302)*, pages 11–20. Cambridge University Press, 2014. doi: 10.1017/S174392131300823X.
- Douglas S. Hall. The RS Canum Venaticorum binaries. In W. S. Fitch, editor, *Multiple Periodic Variable Stars, IAU Colloquium No. 29*, volume 60 of *Astrophysics and Space Science Library*, pages 287–348. 1976.
- Walter S. Fitch, editor. *Multiple periodic variable stars; Proceedings of the Twenty-ninth IAU Colloquium, Budapest, Hungary, September 1-5, 1975*, volume 60 of *Astrophysics and Space Science Library*, January 1976. doi: 10.1007/978-94-010-1175-4.
- E. A. Avvakumova, O. Yu. Malkov, and A Yu Kniazev. Eclipsing variables: Catalogue and classification. *Astronomische Nachrichten*, 334(8):860–865, oct 2013. doi: 10.1002/asna.201311942. URL <https://doi.org/10.1002/asna.201311942>.
- D. Montes, M. J. Fernandez-Figueroa, E. de Castro, and M. Cornide. Excess H α emission in chromospherically active binaries: the spectroscopic survey. , 109:135–145, January 1995.
- Manuel Güdel. X-ray astronomy of stellar coronae. *The Astronomy and Astrophysics Review*, 12(2):71–237, September 2004.
- Yutaka Uchida, Takeo Kosugi, and Hugh S. Hudson, editors. *Magnetodynamic phenomena in the solar atmosphere. Prototypes of stellar magnetic activity*, January 1996.
- A. Collier Cameron. Stellar Prominences. In C. J. Butler and J. G. Doyle, editors, *Solar and Stellar Activity: Similarities and Differences*, volume 158 of *Astronomical Society of the Pacific Conference Series*, page 146, January 1999.
- E. N. Parker. The Generation of Magnetic Fields in Astrophysical Bodies. I. The Dynamo Equations. , 162:665, November 1970. doi: 10.1086/150697.
- C. J. Schrijver and C. Zwaan. *Solar and Stellar Magnetic Activity*. Cambridge Astrophysics. Cambridge University Press, 2000. doi: 10.1017/CBO9780511525261.

- David Pontin and Eric Priest. Magnetic reconnection: Mhd theory and modelling. *Living Reviews in Solar Physics*, 19, 05 2022. doi: 10.1007/s41116-022-00032-9.
- H. W. Babcock. The Topology of the Sun's Magnetic Field and the 22-Year Cycle. , 133:572, March 1961. doi: 10.1086/147060.
- Markus Aschwanden. Physics of the solar corona an introduction with problems and solutions. dec 2005. doi: 10.1007/b138031.
- Michael Stix. *The sun: an introduction*. 2002.
- David F. Gray. *The Observation and Analysis of Stellar Photospheres*. 2005. doi: 10.1017/CBO9781316036570.
- David H. Hathaway. The Solar Cycle. *Living Reviews in Solar Physics*, 12(1):4, December 2015. doi: 10.1007/lrsp-2015-4.
- Christopher M. Johns-Krull. The magnetic fields of classical t tauri stars. *The Astrophysical Journal*, 664(2):975, aug 2007. doi: 10.1086/519017. URL <https://dx.doi.org/10.1086/519017>.
- V. See, M. Jardine, A. A. Vidotto, P. Petit, S. C. Marsden, S. V. Jeffers, and J. D. do Nascimento. The effects of stellar winds on the magnetospheres and potential habitability of exoplanets. , 570: A99, October 2014. doi: 10.1051/0004-6361/201424323.
- Javier Serna. *Stellar Rotation of Young Stars*. PhD thesis, UNAM, Institute of Astronomy, December 2023.
- A. Kalimeris, H. Rovithis-Livaniou, and P. Rovithis. A spot model for the O-C diagrams of AR Lac and Algol. , 387:969–976, August 2002. doi: 10.1051/0004-6361:20020486.
- A. F. Lanza and M. Rodonò. Timescales of magnetic activity in late-type stars. , 349:887–901, August 1999.
- H. Frieboes-Conde and T. Herczeg. Apsidal motion and light-time effect in AS Camelopardalis. , 4:78, 1970.

- T. Borkovits, M. M. Elkhateeb, Sz. Csizmadia, J. Nuspl, I. B. Bíró, T. Hegedüs, and R. Csorvási. Analysis of the O-C diagrams of the W UMa-type systems RZ Com, AD Cnc and V523 Cas. , 441(3):1087–1097, November 2005. doi: 10.1051/0004-6361:20052836.
- S. Rappaport, K. Deck, A. Levine, T. Borkovits, J. Carter, I. El Mellah, R. Sanchis-Ojeda, and B. Kallomeni. KOI-126: A Triply Eclipsing Hierarchical Triple with Two Low-mass Stars in a 1.8 Day Orbit and an Evolved F Star Primary. , 768(1):33, April 2013. doi: 10.1088/0004-637X/768/1/33.
- P. Mayer. Observations of contact binaries - Period changes. *Bulletin of the Astronomical Institutes of Czechoslovakia*, 41:231–238, 1990.
- T. Borkovits and I. B. Bíró. Light-time effect in close binaries with early-type components. , 138: 129–140, July 1999. doi: 10.1051/aas:1999238.
- Kyle E. Conroy, Andrej Prša, Keivan G. Stassun, Jerome A. Orosz, Daniel C. Fabrycky, and William F. Welsh. Kepler Eclipsing Binary Stars. V. Identification of 31 Candidate Eclipsing Binaries in Triple Systems via Eclipse Timing Variations. , 147(2):45, January 2014. doi: 10.1088/0004-6256/147/2/45.
- S.-B. Qian. Are the period variations of W UMa-type LCBs orbital period changes or results of spot activity? I. AD Cnc, V W Cep, V523 Cas and OO Aql. , 328(2):635–644, December 2001. doi: 10.1046/j.1365-8711.2001.04903.x.
- Laurens van der Maaten, Eric O. Postma, and Jaap van den Herik. Dimensionality reduction: A comparative review. *Journal of Machine Learning Research*, 10:66–71, 2009. URL http://www.jmlr.org/papers/volume10/vandermaaten09a/vandermaaten09a.pdf?origin=publication_detail.
- Carlos Oscar Sánchez Sorzano, Javier Vargas, and Addison J. Pascual-Montano. A survey of dimensionality reduction techniques. *arXiv preprint arXiv:1403.2877*, 2014.
- Ian T. Jolliffe. *Principal Component Analysis*. Springer Series in Statistics. Springer, 2nd edition, 2002.

- Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9:2579–2605, 2008. URL <http://www.jmlr.org/papers/v9/vandermaaten08a.html>.
- Martin Wattenberg, Fernanda B. Viégas, and Ian Johnson. How to use t-sne effectively. *Distill*, oct 2016. doi: 10.23915/distill.00002. URL <https://distill.pub/2016/misread-tsne>.
- Laurens van der Maaten. Accelerating t-sne using tree-based algorithms. *Journal of Machine Learning Research*, 15:3221–3245, 2014. URL <http://www.jmlr.org/papers/v15/vandermaaten14a.html>.
- Leland McInnes, John Healy, and James Melville. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *Journal of Open Source Software*, 3(29):861, 2018. doi: 10.21105/joss.00861.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. URL <http://www.deeplearningbook.org>.
- Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted boltzmann machines. In *ICML*, 2010.
- Xavier Glorot, Antoine Bordes, and Yoshua Bengio. Deep sparse rectifier neural networks. *AIS-TATS*, 2011.
- Matthew D. Zeiler and Rob Fergus. Visualizing and understanding convolutional networks. In *ECCV*, 2014.
- Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5:157–166, 1994. doi: 10.1109/72.279181.
- Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6: 107–116, 1998. doi: 10.1142/S021848859800009X.

- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Identity mappings in deep residual networks. In *ECCV*, 2016b.
- Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. ImageNet: A Large-Scale Hierarchical Image Database. *CVPR*, pages 248–255, 2009. doi: 10.1109/CVPR.2009.5206848.
- Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *NIPS*, 2012. URL <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>.
- Simon Kornblith, Jonathon Shlens, and Quoc V. Le. Do better imagenet models transfer better? In *CVPR*, pages 2661–2671, 2019.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *KDD*, pages 226–231, 1996.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *ICLR (Workshop)*, 2019. URL <https://arxiv.org/abs/1711.05101>.
- Yoshihide Kozai. Secular perturbations of asteroids with high inclination and eccentricity. , 67: 591, November 1962. doi: 10.1086/108790.
- M. L. Lidov. The evolution of orbits of artificial satellites of planets under the action of gravitational perturbations of external bodies. *Planetary and Space Science*, 9(5):719–759, May 1962. doi: 10.1016/0032-0633(62)90129-0.
- Daniel Fabrycky and Scott Tremaine. Shrinking Binary and Planetary Orbits by Kozai Cycles with Tidal Friction. , 669(2):1298–1315, June 2007. doi: 10.1086/521702.
- R. Szabó. The Blazhko effect: an unsolved problem of stellar pulsation. *Astronomische Nachrichten*, 331(3):218, March 2010. doi: 10.1002/asna.200911309.
- U. Heber. Hot Subdwarfs. , 128(966):082001, May 2016. doi: 10.1088/1538-3873/128/966/082001.

- James H. Applegate. A mechanism for orbital period modulation in close binaries. , 385:621–629, June 1992. doi: 10.1086/170967.
- J. M. Kreiner, C.-H. Kim, and I.-S. Nha. *An Atlas of O-C Diagrams of Eclipsing Variables*. Wydawnictwo Naukowe Akademii Pedagogicznej, Kraków, 2001.
- Min Lin, Qiang Chen, and Shuicheng Yan. Network in network. In *ICLR*, 2014.
- Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015.
- Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *CVPR*, 2017.
- Saining Xie, Ross B. Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. In *CVPR*, 2017.
- A. Gimenez and J. M. Garcia-Pelayo. Apsidal motion in eclipsing binaries. , 115(1):141–149, 1985. doi: 10.1007/BF00650006.

10. Anexo

10.1. hiperparámetros de los coeficientes

Tabla 10: Hiperparámetros explorados y seleccionados para las técnicas de reducción de dimensionalidad y el algoritmo de agrupamiento DBSCAN, aplicados a los tres coeficientes de correlación (Pearson, Spearman, Kendall) estandarizados.

Técnica	Hiperparámetro	Rango Exploratorio	Valor Seleccionado
t-SNE	n_components	2 (fijo)	2
	Perplejidad (perplexity)	5, 15, 30 , 50	30
	random_state	42 (fijo)	42
UMAP	n_components	2 (fijo)	2
	Número de Vecinos (n_neighbors)	5, 15 , 30, 50	15
	Distancia Mínima (min_dist)	0.0, 0.1 , 0.25, 0.5	0.1
	random_state	42 (fijo)	42
DBSCAN (sobre UMAP)	Epsilon (ϵ)	0.5 – 2.0 (pasos de 0.1)	1.0
	Muestras Mínimas (min_samples)	3, 5 , 10, 15	5
	Métrica (metric)	Euclidiana (defecto)	Euclidiana
DBSCAN (sobre t-SNE)	Epsilon (ϵ)	1.0 – 5.0 (pasos de 0.2)	2.8
	Muestras Mínimas (min_samples)	3, 5 , 10, 15	5
	Métrica (metric)	Euclidiana (defecto)	Euclidiana
DBSCAN (sobre PCA)	Epsilon (ϵ)	0.05 – 0.2 (pasos de 0.01)	0.093
	Muestras Mínimas (min_samples)	10, 15, 20 , 25	20
	Métrica (metric)	Euclidiana (defecto)	Euclidiana

Resumen de ResNet-50 Modificada

Input: (1, 224, 224)

Output Neurons (FC): 6

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 64, 112, 112]	3,136
BatchNorm2d-2	[-1, 64, 112, 112]	128
ReLU-3	[-1, 64, 112, 112]	0

Layer (type)	Output Shape	Param #
MaxPool2d-4	[-1, 64, 56, 56]	0
Conv2d-5	[-1, 64, 56, 56]	4,096
BatchNorm2d-6	[-1, 64, 56, 56]	128
ReLU-7	[-1, 64, 56, 56]	0
Conv2d-8	[-1, 64, 56, 56]	36,864
BatchNorm2d-9	[-1, 64, 56, 56]	128
ReLU-10	[-1, 64, 56, 56]	0
Conv2d-11	[-1, 256, 56, 56]	16,384
BatchNorm2d-12	[-1, 256, 56, 56]	512
Conv2d-13	[-1, 256, 56, 56]	16,384
BatchNorm2d-14	[-1, 256, 56, 56]	512
ReLU-15	[-1, 256, 56, 56]	0
Bottleneck-16	[-1, 256, 56, 56]	0
Conv2d-17	[-1, 64, 56, 56]	16,384
BatchNorm2d-18	[-1, 64, 56, 56]	128
ReLU-19	[-1, 64, 56, 56]	0
Conv2d-20	[-1, 64, 56, 56]	36,864
BatchNorm2d-21	[-1, 64, 56, 56]	128
ReLU-22	[-1, 64, 56, 56]	0
Conv2d-23	[-1, 256, 56, 56]	16,384
BatchNorm2d-24	[-1, 256, 56, 56]	512
ReLU-25	[-1, 256, 56, 56]	0
Bottleneck-26	[-1, 256, 56, 56]	0
Conv2d-27	[-1, 64, 56, 56]	16,384
BatchNorm2d-28	[-1, 64, 56, 56]	128

Layer (type)	Output Shape	Param #
ReLU-29	[-1, 64, 56, 56]	0
Conv2d-30	[-1, 64, 56, 56]	36,864
BatchNorm2d-31	[-1, 64, 56, 56]	128
ReLU-32	[-1, 64, 56, 56]	0
Conv2d-33	[-1, 256, 56, 56]	16,384
BatchNorm2d-34	[-1, 256, 56, 56]	512
ReLU-35	[-1, 256, 56, 56]	0
Bottleneck-36	[-1, 256, 56, 56]	0
Conv2d-37	[-1, 128, 56, 56]	32,768
BatchNorm2d-38	[-1, 128, 56, 56]	256
ReLU-39	[-1, 128, 56, 56]	0
Conv2d-40	[-1, 128, 28, 28]	147,456
BatchNorm2d-41	[-1, 128, 28, 28]	256
ReLU-42	[-1, 128, 28, 28]	0
Conv2d-43	[-1, 512, 28, 28]	65,536
BatchNorm2d-44	[-1, 512, 28, 28]	1,024
Conv2d-45	[-1, 512, 28, 28]	131,072
BatchNorm2d-46	[-1, 512, 28, 28]	1,024
ReLU-47	[-1, 512, 28, 28]	0
Bottleneck-48	[-1, 512, 28, 28]	0
Conv2d-49	[-1, 128, 28, 28]	65,536
BatchNorm2d-50	[-1, 128, 28, 28]	256
ReLU-51	[-1, 128, 28, 28]	0
Conv2d-52	[-1, 128, 28, 28]	147,456
BatchNorm2d-53	[-1, 128, 28, 28]	256

Layer (type)	Output Shape	Param #
ReLU-54	[-1, 128, 28, 28]	0
Conv2d-55	[-1, 512, 28, 28]	65,536
BatchNorm2d-56	[-1, 512, 28, 28]	1,024
ReLU-57	[-1, 512, 28, 28]	0
Bottleneck-58	[-1, 512, 28, 28]	0
Conv2d-59	[-1, 128, 28, 28]	65,536
BatchNorm2d-60	[-1, 128, 28, 28]	256
ReLU-61	[-1, 128, 28, 28]	0
Conv2d-62	[-1, 128, 28, 28]	147,456
BatchNorm2d-63	[-1, 128, 28, 28]	256
ReLU-64	[-1, 128, 28, 28]	0
Conv2d-65	[-1, 512, 28, 28]	65,536
BatchNorm2d-66	[-1, 512, 28, 28]	1,024
ReLU-67	[-1, 512, 28, 28]	0
Bottleneck-68	[-1, 512, 28, 28]	0
Conv2d-69	[-1, 128, 28, 28]	65,536
BatchNorm2d-70	[-1, 128, 28, 28]	256
ReLU-71	[-1, 128, 28, 28]	0
Conv2d-72	[-1, 128, 28, 28]	147,456
BatchNorm2d-73	[-1, 128, 28, 28]	256
ReLU-74	[-1, 128, 28, 28]	0
Conv2d-75	[-1, 512, 28, 28]	65,536
BatchNorm2d-76	[-1, 512, 28, 28]	1,024
ReLU-77	[-1, 512, 28, 28]	0
Bottleneck-78	[-1, 512, 28, 28]	0

Layer (type)	Output Shape	Param #
Conv2d-79	[-1, 256, 28, 28]	131,072
BatchNorm2d-80	[-1, 256, 28, 28]	512
ReLU-81	[-1, 256, 28, 28]	0
Conv2d-82	[-1, 256, 14, 14]	589,824
BatchNorm2d-83	[-1, 256, 14, 14]	512
ReLU-84	[-1, 256, 14, 14]	0
Conv2d-85	[-1, 1024, 14, 14]	262,144
BatchNorm2d-86	[-1, 1024, 14, 14]	2,048
Conv2d-87	[-1, 1024, 14, 14]	524,288
BatchNorm2d-88	[-1, 1024, 14, 14]	2,048
ReLU-89	[-1, 1024, 14, 14]	0
Bottleneck-90	[-1, 1024, 14, 14]	0
Conv2d-91	[-1, 256, 14, 14]	262,144
BatchNorm2d-92	[-1, 256, 14, 14]	512
ReLU-93	[-1, 256, 14, 14]	0
Conv2d-94	[-1, 256, 14, 14]	589,824
BatchNorm2d-95	[-1, 256, 14, 14]	512
ReLU-96	[-1, 256, 14, 14]	0
Conv2d-97	[-1, 1024, 14, 14]	262,144
BatchNorm2d-98	[-1, 1024, 14, 14]	2,048
ReLU-99	[-1, 1024, 14, 14]	0
Bottleneck-100	[-1, 1024, 14, 14]	0
Conv2d-101	[-1, 256, 14, 14]	262,144
BatchNorm2d-102	[-1, 256, 14, 14]	512
ReLU-103	[-1, 256, 14, 14]	0

Layer (type)	Output Shape	Param #
Conv2d-104	[-1, 256, 14, 14]	589,824
BatchNorm2d-105	[-1, 256, 14, 14]	512
ReLU-106	[-1, 256, 14, 14]	0
Conv2d-107	[-1, 1024, 14, 14]	262,144
BatchNorm2d-108	[-1, 1024, 14, 14]	2,048
ReLU-109	[-1, 1024, 14, 14]	0
Bottleneck-110	[-1, 1024, 14, 14]	0
Conv2d-111	[-1, 256, 14, 14]	262,144
BatchNorm2d-112	[-1, 256, 14, 14]	512
ReLU-113	[-1, 256, 14, 14]	0
Conv2d-114	[-1, 256, 14, 14]	589,824
BatchNorm2d-115	[-1, 256, 14, 14]	512
ReLU-116	[-1, 256, 14, 14]	0
Conv2d-117	[-1, 1024, 14, 14]	262,144
BatchNorm2d-118	[-1, 1024, 14, 14]	2,048
ReLU-119	[-1, 1024, 14, 14]	0
Bottleneck-120	[-1, 1024, 14, 14]	0
Conv2d-121	[-1, 256, 14, 14]	262,144
BatchNorm2d-122	[-1, 256, 14, 14]	512
ReLU-123	[-1, 256, 14, 14]	0
Conv2d-124	[-1, 256, 14, 14]	589,824
BatchNorm2d-125	[-1, 256, 14, 14]	512
ReLU-126	[-1, 256, 14, 14]	0
Conv2d-127	[-1, 1024, 14, 14]	262,144
BatchNorm2d-128	[-1, 1024, 14, 14]	2,048

Layer (type)	Output Shape	Param #
ReLU-129	[-1, 1024, 14, 14]	0
Bottleneck-130	[-1, 1024, 14, 14]	0
Conv2d-131	[-1, 256, 14, 14]	262,144
BatchNorm2d-132	[-1, 256, 14, 14]	512
ReLU-133	[-1, 256, 14, 14]	0
Conv2d-134	[-1, 256, 14, 14]	589,824
BatchNorm2d-135	[-1, 256, 14, 14]	512
ReLU-136	[-1, 256, 14, 14]	0
Conv2d-137	[-1, 1024, 14, 14]	262,144
BatchNorm2d-138	[-1, 1024, 14, 14]	2,048
ReLU-139	[-1, 1024, 14, 14]	0
Bottleneck-140	[-1, 1024, 14, 14]	0
Conv2d-141	[-1, 512, 14, 14]	524,288
BatchNorm2d-142	[-1, 512, 14, 14]	1,024
ReLU-143	[-1, 512, 14, 14]	0
Conv2d-144	[-1, 512, 7, 7]	2,359,296
BatchNorm2d-145	[-1, 512, 7, 7]	1,024
ReLU-146	[-1, 512, 7, 7]	0
Conv2d-147	[-1, 2048, 7, 7]	1,048,576
BatchNorm2d-148	[-1, 2048, 7, 7]	4,096
Conv2d-149	[-1, 2048, 7, 7]	2,097,152
BatchNorm2d-150	[-1, 2048, 7, 7]	4,096
ReLU-151	[-1, 2048, 7, 7]	0
Bottleneck-152	[-1, 2048, 7, 7]	0
Conv2d-153	[-1, 512, 7, 7]	1,048,576

Layer (type)	Output Shape	Param #
BatchNorm2d-154	[-1, 512, 7, 7]	1,024
ReLU-155	[-1, 512, 7, 7]	0
Conv2d-156	[-1, 512, 7, 7]	2,359,296
BatchNorm2d-157	[-1, 512, 7, 7]	1,024
ReLU-158	[-1, 512, 7, 7]	0
Conv2d-159	[-1, 2048, 7, 7]	1,048,576
BatchNorm2d-160	[-1, 2048, 7, 7]	4,096
ReLU-161	[-1, 2048, 7, 7]	0
Bottleneck-162	[-1, 2048, 7, 7]	0
Conv2d-163	[-1, 512, 7, 7]	1,048,576
BatchNorm2d-164	[-1, 512, 7, 7]	1,024
ReLU-165	[-1, 512, 7, 7]	0
Conv2d-166	[-1, 512, 7, 7]	2,359,296
BatchNorm2d-167	[-1, 512, 7, 7]	1,024
ReLU-168	[-1, 512, 7, 7]	0
Conv2d-169	[-1, 2048, 7, 7]	1,048,576
BatchNorm2d-170	[-1, 2048, 7, 7]	4,096
ReLU-171	[-1, 2048, 7, 7]	0
Bottleneck-172	[-1, 2048, 7, 7]	0
AdaptiveAvgPool2d-173	[-1, 2048, 1, 1]	0
Linear-174	[-1, 6]	12,294

Total params: 23,514,054

Trainable params: 23,514,054

Non-trainable params: 0

Input size (MB): 0.19

Forward/backward pass size (MB): 286.55

Params size (MB): 89.70

Estimated Total Size (MB): 376.44

10.2. Hiperparámetros del modelo

Tabla 12: Hiperparámetros y componentes clave utilizados para el entrenamiento del modelo ResNet50.

Parámetro/Componente	Valor/Configuración
Arquitectura Base	ResNet50 (con pesos pre-entrenados en ImageNet)
Modificación de Capa de Entrada	conv1 adaptada para 1 canal (escala de grises)
Modificación de Capa de Salida	fc reemplazada por <code>nn.Linear(2048, 6)</code>
Tamaño de Imagen de Entrada	224×224 píxeles
Normalización de Píxeles	Media = 0.5, Desv. Est. = 0.5 (por canal)
Función de Pérdida	Entropía Cruzada (<code>CrossEntropyLoss</code>)
Optimizador	AdamW
Tasa de Aprendizaje Inicial	3×10^{-4}
Planificador de Tasa de Aprendizaje	<code>ReduceLROnPlateau</code>
Factor de Reducción (LR Scheduler)	0.1
Paciencia (LR Scheduler)	3 épocas
Tamaño del Batch (Batch Size)	32
Número Máximo de Épocas	50
Parada Temprana (Early Stopping)	Sí
Paciencia (Early Stopping)	7 épocas
Métrica Monitoreada (Early Stopping)	Precisión de Validación
División de Datos	Entrenamiento: 72 %, Validación: 8 %, Prueba: 20 %
Estratificación	Por clase
Precisión Mixta (AMP)	Habilitada (con <code>torch.amp</code>)
Framework	PyTorch

Nota: Algunos valores, como la paciencia del LR Scheduler, pueden derivarse de otros parámetros (e.g., `'patience // 2'`).

10.3. Tablas con los resultados

Tabla 13: Sistemas Kepler en Clase Predicha C0 (Anticorrelated - Manchas) con su Período Orbital. Total: 230 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10014536	0	1,0094	3965556	0	6,5568	7622059	0	10,4033
10020247	0	0,3456	4070376	0	1,6346	7668283	0	0,5375
10024144	0	0,8156	4248941	0	8,6446	7686918	0	2,5188
10032392	0	0,3912	4357272	0	2,0859	7765894	0	3,2045
10119517	0	0,7375	4358206	0	0,9512	7833144	0	2,2477
10149237	0	0,2980	4372379	0	4,5352	7836330	0	0,6584
10159014	0	8,7774	4649324	0	1,0357	7884426	0	0,2967
10221886	0	8,3167	4665989	0	2,2481	7907688	0	4,3448
10228240	0	2,1734	4743626	0	1,3029	7976783	0	1,2089
10255110	0	0,3367	4852055	0	2,4149	8111387	0	1,2736
10259530	0	0,7072	5000179	0	3,6329	8113154	0	2,5869
10357852	0	0,4883	5041569	0	2,5354	8143757	0	0,3565
10389596	0	2,6093	5041975	0	2,9599	8219268	0	6,2467
10417135	0	1,2033	5088735	0	0,5075	8242350	0	6,9936
10422852	0	1,3989	5112567	0	1,6159	8263940	0	0,5155
10447902	0	0,3375	5123176	0	0,7078	8264510	0	5,6868
10535807	0	1,4817	5127005	0	1,6211	8314879	0	0,8778
10551346	0	1,4280	5215700	0	1,3124	8328376	0	4,3460
10586874	0	0,5355	5215999	0	2,5312	8432040	0	5,3278
10600319	0	0,2815	5283839	0	0,3152	8432859	0	0,3512
10618253	0	0,4374	5306862	0	2,0256	8452840	0	1,2012
10679505	0	5,6752	5353374	0	0,3933	8456774	0	2,8863
10680475	0	0,3498	5353653	0	0,3686	8456998	0	7,5315
10711938	0	0,3576	5377349	0	1,1168	8508485	0	12,5958
10844279	0	0,6234	5428668	0	NaN	8548416	0	1,1636
10863286	0	3,7239	5444392	0	1,5195	8552540	0	1,0619
10873904	0	9,8856	5450322	0	0,4240	8608490	0	1,0828
10905824	0	2,7195	5458880	0	3,5117	8654097	0	3,0416
10989032	0	2,3051	5461570	0	0,5077	8696442	0	12,3606
11091082	0	0,3851	5563814	0	0,3082	8707639	0	7,7852
11180361	0	0,5331	5598639	0	1,2976	8736072	0	0,4776
11247386	0	0,3943	5623774	0	1,1336	8758161	0	0,9982
11352791	0	0,2805	5707897	0	NaN	8814635	0	0,5504
11402381	0	0,4174	5716244	0	1,3303	8848288	0	5,5665
11494583	0	0,2483	5791886	0	0,3252	8868649	0	4,4474
11559864	0	0,3833	5891963	0	0,2820	8872737	0	0,4591
11572363	0	19,0278	5966237	0	0,3976	8878719	0	0,3646
11618883	0	0,6849	5977736	0	1,5791	8892722	0	1,7944
11649962	0	10,5627	5988465	0	7,0565	8912911	0	3,4636
11751847	0	0,3315	6024572	0	0,4149	8937663	0	0,9416
11774013	0	3,7562	6137885	0	NaN	8958670	0	2,4253
11920266	0	0,4674	6197319	0	1,6638	9004380	0	0,2503
11924311	0	0,4451	6209824	0	1,2630	9030817	0	2,0262
11973705	0	6,7721	6286402	0	0,3433	9071104	0	0,3852
12016304	0	1,0241	6311637	0	1,6208	9092303	0	2,5772
12055421	0	0,3856	6353203	0	0,5085	9137992	0	1,4700
12108333	0	0,7054	6370665	0	0,9323	9159301	0	3,0448

Tabla 15: Sistemas Kepler en Clase Predicha C0 (Anticorrelated - Manchas) con su Período Orbital. Total: 230 sistemas. (Parte 2)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
12255108	0	9,1315	6372268	0	5,2200	9163674	0	1,5463
12418319	0	1,3570	6421483	0	2,1584	9180282	0	3,0376
12458133	0	0,3325	6443538	0	6,2614	9237533	0	1,8687
12553806	0	0,4631	6549491	0	0,7647	9414905	0	0,4565
1573836	0	3,5571	6593575	0	0,3457	9419603	0	1,0524
2141697	0	0,3310	6665064	0	0,6984	9451096	0	1,2504
2162283	0	0,9064	6670812	0	1,7418	9466316	0	0,3525
2305277	0	0,3788	6695510	0	2,1730	9475663	0	0,7080
2308957	0	2,2197	6775034	0	10,0285	9508052	0	0,2800
2448320	0	0,2741	6778050	0	0,9458	9508954	0	1,1006
2577756	0	0,8703	6803335	0	1,1109	9532591	0	0,3584
2694741	0	0,3266	6863229	0	1,9949	9544350	0	2,2598
2717141	0	0,3946	6881709	0	6,7411	9552668	0	2,3874
2831632	0	2,5732	6964796	0	0,4000	9602542	0	1,4632
2835289	0	0,8578	7038831	0	NaN	9637265	0	1,8555
2851474	0	2,7683	7039026	0	9,9439	9649493	0	0,3716
2856960	0	0,2585	7177892	0	1,3862	9651298	0	2,1551
3339563	0	0,8412	7280704	0	0,3244	9700181	0	2,8486
3439180	0	0,3251	7282128	0	0,3471	9701423	0	8,6074
3443519	0	0,3536	7348206	0	0,4012	9702641	0	0,5032
3545476	0	0,3177	7373255	0	13,6611	9776718	0	0,5444
3641446	0	2,1000	7433513	0	0,7011	9788113	0	2,0681
3656322	0	3,6637	7511416	0	5,5909	9827122	0	2,1549
3659940	0	0,8963	7515679	0	5,5904	9835416	0	4,0366
3662635	0	0,9394	7532973	0	2,1446	9842890	0	4,9884
3761175	0	5,1623	7546429	0	0,3521	9851943	0	2,1639
3848919	0	1,0473	7549265	0	1,9624	9851944	0	2,1639
3851193	0	1,3411	7584739	0	0,9116	9906590	0	1,6863
3862171	0	6,9965	7591456	0	5,8358	9970937	0	4,8771
3957477	0	0,9791	7610486	0	0,4577			

Tabla 17: Sistemas Kepler en Clase Predicha C1 (Correlated Oscillatory - LTTE) con su Período Orbital. Total: 140 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10004546	1	19,3569	4554004	1	0,7425	7887124	1	32,4864
10092506	1	31,0417	4647652	1	1,0648	7897952	1	66,9916
10096019	1	NaN	4659476	1	58,9964	7941635	1	0,7627
10096864	1	1,9467	4669402	1	8,4965	7973970	1	9,4799
10149845	1	4,0564	4761060	1	3,3614	8043961	1	1,5592
10198097	1	2,8152	4850874	1	1,7759	8095275	1	23,0073
10226388	1	0,6607	4909707	1	2,3024	8099615	1	1,9007
10227863	1	5,1397	5017127	1	20,0064	8108785	1	0,2288
10383620	1	0,7346	5090937	1	8,8007	8112039	1	41,8082
10611450	1	11,6527	5175668	1	21,8821	8144355	1	80,5141
10664416	1	25,3222	5196301	1	1,9104	8145477	1	0,5658
10991989	1	0,9745	5213466	1	2,8193	8192840	1	0,4335
11133313	1	27,4009	5376552	1	0,5038	8197368	1	9,0879
11236035	1	2,3190	5385723	1	12,4449	8265951	1	0,7800
11303811	1	3,3795	5386810	1	0,8889	8322564	1	22,2588
11404698	1	0,5902	5398002	1	14,1532	8386865	1	1,2580
11560447	1	0,5277	5475712	1	2,9919	8386982	1	72,2596
11568657	1	13,4760	5513861	1	1,5102	8459354	1	53,5573
11616594	1	14,5876	5615528	1	0,3392	8563964	1	0,3384
11671660	1	8,7103	5647008	1	0,7999	8616873	1	0,5761
11859811	1	22,3141	5736537	1	1,7615	8652599	1	1,3610
11923629	1	17,9733	5771961	1	26,0664	8688110	1	374,5460
12055255	1	0,2209	5785586	1	0,4596	8838070	1	43,3627
12071006	1	6,0960	5818706	1	14,9599	8848104	1	0,8249
12508348	1	0,2556	5881838	1	0,3003	8868650	1	4,4474
2444348	1	103,2070	5956588	1	0,2729	8893936	1	4,2445
2569494	1	1,5233	5960989	1	50,7215	8908102	1	5,4146
2695740	1	3,6159	6042191	1	43,3909	8912308	1	20,1744
2720096	1	26,6747	6105491	1	13,2996	8972908	1	4,2001
2831097	1	0,3770	6141791	1	13,6590	8977179	1	3,1962
2969628	1	3,9465	6290740	1	15,1518	9016693	1	26,3680
3228863	1	0,7309	6432059	1	0,7697	9028024	1	3,8579
3240976	1	15,2389	6526545	1	2,1014	9075704	1	0,5132
3440230	1	2,8811	6629588	1	2,2645	9108579	1	1,1696
3442058	1	NaN	6693555	1	10,8750	9328852	1	0,6459
3729724	1	16,4188	6791604	1	0,5288	9408183	1	49,6835
3734660	1	19,9421	6963171	1	23,3082	9489411	1	6,6889
3749404	1	NaN	7272739	1	0,2812	9512958	1	3,2372
3749508	1	1,0657	7273033	1	0,3050	9596037	1	33,3556
3850086	1	19,1142	7350038	1	13,8299	9665086	1	0,2965
3954227	1	0,5943	7362751	1	0,3382	9722737	1	0,4185
4059656	1	4,0594	7375612	1	0,1601	9767437	1	0,7127
4069063	1	0,5043	7385478	1	1,6555	9790355	1	14,5655
4075067	1	2,7544	7523733	1	3,1212	9840412	1	0,8785
4359851	1	13,5423	7672068	1	16,8362	9848190	1	5,2410
4455763	1	0,7663	7697065	1	0,2728	9912977	1	1,8879
4545729	1	18,3835	7770471	1	1,1578			

Tabla 19: Sistemas Kepler en Clase Predicha C2 (Correlated Parabolic - Cambio Secular) con su Período Orbital. Total: 79 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10216186	2	0,6059	4074532	2	0,3532	8234477	2	4,0287
10454725	2	0,8318	4169521	2	1,1726	8257903	2	0,5151
10481912	2	0,4424	4681152	2	1,8359	8311255	2	0,5791
10556068	2	2,1172	4851217	2	2,4703	8496820	2	0,4370
10581918	2	1,8019	5211385	2	1,6607	8553788	2	1,6062
10711646	2	0,7377	5266937	2	5,9171	8620561	2	0,7820
10802917	2	0,2725	5269407	2	0,9589	8624778	2	0,2763
10905804	2	0,7511	5296877	2	0,3773	8625469	2	0,3022
10991769	2	3,2813	5369419	2	0,4377	8823666	2	0,4325
11144556	2	0,6430	5471619	2	0,9628	8894630	2	1,0840
11295347	2	0,8884	5479973	2	1,7953	8906039	2	2,3475
11338865	2	0,8804	5535061	2	0,4634	8953296	2	0,7843
11444780	2	0,2867	5621294	2	0,9389	9051716	2	1,3908
11612091	2	0,4543	5733154	2	62,5199	9108058	2	2,1749
11825204	2	0,2096	5820209	2	0,6561	9164561	2	1,2670
11875706	2	0,3857	5872696	2	0,1726	9207508	2	2,0152
12055014	2	0,4999	5956776	2	0,5691	9291368	2	3,7965
12157987	2	0,5778	6302051	2	0,6659	9394601	2	0,8768
2708156	2	1,8913	6314173	2	1,4333	9402652	2	1,0731
3104113	2	0,8468	6370361	2	0,4549	9532219	2	0,1982
3127873	2	0,6715	6447430	2	1,1600	9657096	2	2,1382
3221207	2	0,4738	6464285	2	0,8437	9716456	2	1,8133
3338660	2	1,8734	6677225	2	0,5250	9724080	2	1,1739
3437778	2	0,6356	6689368	2	1,2701	9833618	2	1,4085
3766353	2	2,6670	7335517	2	0,2745	9837083	2	0,6234
3953981	2	0,4920	7884842	2	1,3145			
4071600	2	1,6746	8122124	2	0,2493			

Tabla 21: Sistemas Kepler en Clase Predicha C3 (Flat/Noisy - Sin Señal Clara) con su Período Orbital. Total: 259 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10007533	3	0,6481	4574310	3	1,3062	7749504	3	0,5662
10030943	3	0,2358	4729553	3	0,9613	7766185	3	0,8355
10135584	3	0,3913	4738426	3	0,2488	7767774	3	0,1734
10191056	3	2,4275	4826439	3	2,4743	7769072	3	0,6089
10191070	3	1,2137	4843592	3	0,4835	7777443	3	0,8851
10208759	3	4,5750	4853067	3	1,3409	7812455	3	0,9036
10267044	3	0,4300	4857282	3	0,2508	7816201	3	0,5750
10274218	3	1,7641	4946584	3	0,4540	7835348	3	0,6641
10275747	3	0,6617	4947528	3	0,4970	7881722	3	0,9533
10292413	3	0,5592	4949214	3	0,9220	7886329	3	0,5675
10341913	3	1,8675	4999260	3	0,3784	7968880	3	1,7739
10342041	3	1,8675	4999357	3	0,9901	7975824	3	0,4038
10363300	3	0,9349	5018787	3	0,6072	8059303	3	0,3734
10407221	3	0,9337	5025261	3	2,1714	8081389	3	1,4894
10485069	3	0,4453	5041843	3	0,4572	8177958	3	1,2353
10544976	3	0,3505	5097446	3	1,2881	8218274	3	1,1874
10596883	3	0,4689	5104097	3	0,2754	8231231	3	0,7116
10619506	3	0,5036	5166136	3	0,2339	8248812	3	0,6854
10661783	3	1,2314	5198934	3	0,8347	8262223	3	1,6130
10684673	3	0,1926	5201619	3	0,5073	8264534	3	1,4158
10735519	3	0,9071	5259926	3	0,4378	8288741	3	0,2198
10736223	3	1,1051	5296276	3	1,8920	8330575	3	1,9142
10794405	3	0,9524	5302006	3	0,1512	8360184	3	0,4845
10796477	3	0,4850	5307780	3	0,3089	8382182	3	1,2587
10799558	3	0,3665	5310387	3	0,4417	8386198	3	2,5811
10818544	3	1,3692	5389616	3	0,4069	8397460	3	1,4190
10858720	3	0,9524	5394544	3	0,4320	8397675	3	0,5533
10916675	3	0,4189	5439790	3	0,7961	8429415	3	1,3526
10920314	3	0,5052	5440746	3	0,4827	8430210	3	1,9755
10972830	3	0,6785	5474733	3	0,8838	8523194	3	0,8785
11097678	3	0,9997	5529643	3	0,7598	8539720	3	0,7445
11135978	3	0,2921	5534702	3	1,0255	8539850	3	0,6421
11179657	3	0,7889	5696909	3	0,6430	8554005	3	0,6083
11230837	3	0,4461	5703230	3	0,7315	8555795	3	0,2345
11255667	3	0,8189	5733384	3	1,5467	8564672	3	0,4348
11284227	3	0,4376	5737474	3	0,3979	8687088	3	0,9050
11303526	3	0,7201	5770860	3	0,7376	8696274	3	0,3915
11408810	3	0,7493	5773205	3	0,2669	8758716	3	0,1072
11410485	3	0,4288	5785551	3	0,2667	8800998	3	0,8828
11447953	3	1,4989	5792093	3	0,6006	8804824	3	0,4574
11495781	3	0,5079	5809827	3	1,2221	8816790	3	0,2459
11509282	3	0,6340	5809868	3	0,4394	8823397	3	1,5065
11568428	3	1,7106	5887316	3	0,6031	8912468	3	0,0948
11652545	3	0,4128	5952403	3	0,9057	8913061	3	1,0200
11703960	3	0,6044	5963222	3	1,2173	8977390	3	0,6533
11722816	3	0,3204	5978521	3	0,6082	9002076	3	0,4814

Tabla 23: Sistemas Kepler en Clase Predicha C3 (Flat/Noisy - Sin Señal Clara) con su Período Orbital. Total: 259 sistemas. (parte 2)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
11724091	3	1,5591	5980800	3	0,4142	9020426	3	0,9134
11769739	3	0,2525	5991936	3	0,8074	9030447	3	0,5667
11774383	3	0,5202	6026204	3	2,2798	9051723	3	0,4034
11825057	3	0,5321	6042031	3	0,5371	9084778	3	0,5922
11972387	3	0,3279	6044543	3	0,5321	9149789	3	0,7050
12004834	3	0,2623	6046061	3	0,2973	9220600	3	0,9792
12023089	3	0,6234	6067735	3	0,4462	9228778	3	1,5666
12059158	3	0,4718	6072578	3	0,2697	9237149	3	0,5263
12170648	3	0,5994	6223646	3	0,3649	9239684	3	0,2618
12216817	3	0,2463	6293266	3	0,8467	9285587	3	1,8119
12255382	3	0,9993	6311681	3	0,8448	9288175	3	0,2609
12267718	3	0,5451	6350020	3	0,2418	9350889	3	0,7259
12350008	3	0,1845	6387887	3	0,2169	9356753	3	0,5927
12352712	3	0,7221	6390205	3	0,4494	9357275	3	1,5883
12785282	3	0,7887	6443392	3	0,7770	9392682	3	0,8929
1295531	3	1,6864	6462057	3	0,4787	9426970	3	1,7711
1868650	3	0,5847	6469946	3	0,7158	9453192	3	0,7188
2012362	3	0,3863	6531485	3	0,6770	9470054	3	1,4732
2453212	3	0,4367	6606653	3	2,6980	9472174	3	0,1258
2558370	3	0,5462	6613627	3	0,1508	9478836	3	0,2541
2854752	3	0,4704	6699679	3	0,2012	9480516	3	1,4298
2983113	3	0,3952	6805779	3	0,8019	9480977	3	0,8710
3228824	3	0,7309	6880727	3	0,4127	9536053	3	0,4722
3344427	3	0,6518	7013934	3	0,6414	9592145	3	0,4889
3353233	3	0,3158	7051984	3	0,6781	9592855	3	1,2193
3354616	3	0,2770	7091476	3	0,8077	9644680	3	0,5859
3558822	3	1,3534	7198474	3	0,2423	9725155	3	1,1271
3765708	3	0,4314	7203179	3	2,2457	9760531	3	0,2728
3832716	3	1,1419	7258889	3	0,9039	9788457	3	0,9633
3833859	3	0,4317	7366145	3	0,8644	9790965	3	0,8221
3848042	3	0,4115	7373555	3	0,5367	9813678	3	0,5051
3853673	3	0,6438	7382250	3	1,4187	9843451	3	0,4428
3954798	3	0,9185	7383021	3	0,4661	9897710	3	0,4255
3958488	3	0,6229	7456992	3	1,2471	9898401	3	0,1528
3966491	3	1,3520	7501230	3	0,8928	9899181	3	1,3326
3969362	3	0,4106	7620664	3	0,6837	9909497	3	1,2841
4073678	3	0,2882	7630690	3	0,8866	9953894	3	1,3826
4273411	3	1,2197	7698650	3	0,5992	9956124	3	0,3627
4365442	3	1,7144	7707742	3	0,7584	9957411	3	0,3747
4550750	3	1,5678	7733540	3	NaN			
4551328	3	1,0441	7748113	3	1,7347			

Tabla 25: Sistemas Kepler en Clase Predicha C4 (Mixed/Complex - Superposición) con su Período Orbital. Total: 581 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10014830	4	3,0305	4367544	4	2,3912	7660607	4	2,7634
10032935	4	0,3205	4372705	4	1,2787	7676610	4	1,2257
10074939	4	0,2771	4385109	4	0,2746	7680593	4	0,2764
10090246	4	2,2861	4450976	4	12,0449	7685689	4	0,3252
10123627	4	0,2949	4451148	4	0,7360	7690843	4	0,7863
10128961	4	0,3477	4466691	4	0,4827	7691553	4	0,3483
10141087	4	0,4698	4470124	4	11,4390	7696778	4	0,3312
10148799	4	0,3466	4474193	4	0,3225	7700181	4	0,3637
10154189	4	0,4112	4474637	4	3,8867	7700578	4	1,5071
10155563	4	0,3603	4476900	4	0,2797	7709086	4	0,4095
10162999	4	3,4292	4484356	4	1,1442	7740566	4	0,2971
10206340	4	4,5644	4547067	4	0,4076	7744173	4	0,3985
10229723	4	0,6287	4563150	4	0,2747	7773380	4	0,3076
10253375	4	0,3753	4569923	4	0,3136	7818448	4	0,6190
10253421	4	0,4284	4570326	4	1,1216	7821450	4	0,3148
10257903	4	0,8586	4651526	4	0,2981	7839027	4	0,7207
10275197	4	0,3908	4660997	4	0,5626	7871200	4	0,2429
10280990	4	0,3845	4661397	4	0,2923	7877062	4	0,3037
10285661	4	0,3083	4669592	4	0,3784	7878402	4	0,3744
10288502	4	0,2302	4672934	4	0,3827	7879399	4	0,3927
10291683	4	2,0437	4677321	4	1,5722	7885570	4	1,7293
10322296	4	0,3150	4739194	4	1,2466	7889628	4	0,3424
10322582	4	0,2913	4739791	4	0,8989	7890379	4	0,3451
10346522	4	3,9891	4758092	4	0,2892	7905209	4	0,4196
10350225	4	0,2821	4758368	4	3,7499	7936219	4	0,3856
10355671	4	0,3036	4762887	4	0,7366	7941050	4	0,2980
10388897	4	0,3437	4843222	4	0,3874	7950962	4	0,8270
10389809	4	0,3974	4847343	4	11,4169	7953796	4	0,3175
10395202	4	0,3059	4847369	4	12,3500	7977261	4	0,9258
10468514	4	0,4249	4859432	4	0,3855	8004839	4	0,3438
10485137	4	0,4453	4909422	4	0,3951	8009467	4	3,0011
10528299	4	0,3998	4936334	4	0,3544	8012437	4	8,1502
10547209	4	2,2540	4945588	4	1,1291	8016211	4	3,1749
10557008	4	0,2654	4945857	4	0,3354	8016214	4	3,1750
10599397	4	0,9374	4949187	4	11,9774	8027591	4	24,2744
10614158	4	4,4623	4949194	4	41,2632	8028158	4	0,2710
10619109	4	2,0452	4950505	4	0,2948	8029708	4	0,3136
10676927	4	1,0311	4954113	4	0,6680	8039225	4	1,7941
10724533	4	0,7451	4991959	4	0,3609	8053107	4	0,3889
10727655	4	0,3534	5005570	4	0,4228	8087799	4	0,9263
10735564	4	1,6750	5008287	4	0,2919	8097553	4	0,3912
10737574	4	0,3656	5015926	4	0,3627	8097825	4	2,9369
10743600	4	0,8170	5020034	4	2,1191	8097902	4	0,3316
10753751	4	0,4430	5022573	4	0,4417	8112324	4	0,5759
10794878	4	0,4328	5022908	4	0,6372	8123430	4	11,1700
10801703	4	0,3131	5033682	4	0,3799	8151107	4	18,0013
10809970	4	0,4471	5039392	4	236,7279	8153568	4	3,6071

Tabla 27: Sistemas Kepler en Clase Predicha C4 (Mixed/Complex - Superposición) con su Período Orbital. Total: 581 sistemas.(parte 2)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10815379	4	0,8905	5077994	4	0,6963	8166095	4	0,7991
10847118	4	0,2936	5128972	4	0,5053	8182360	4	0,6951
10854621	4	0,3759	5129777	4	26,1585	8183540	4	0,6842
10855535	4	0,1128	5174346	4	0,3506	8183850	4	0,3984
10857342	4	2,4159	5195137	4	0,3241	8190491	4	0,7779
10877703	4	0,4369	5197256	4	6,9634	8190613	4	0,3326
10880490	4	0,2980	5199489	4	0,4648	8211618	4	0,3374
10924462	4	0,3754	5264818	4	1,9051	8211824	4	0,8411
10965091	4	0,2359	5283266	4	0,3146	8222945	4	0,4511
11012801	4	0,3673	5284262	4	NaN	8230815	4	0,3452
11017077	4	0,7086	5286221	4	15,2960	8240109	4	2,3012
11036301	4	0,2852	5290305	4	0,6205	8240861	4	0,8985
11036692	4	0,3589	5357682	4	0,7177	8241252	4	0,3540
11042923	4	0,3902	5357882	4	0,3874	8242493	4	0,2833
11046124	4	4,3074	5358200	4	0,5359	8245326	4	0,3308
11071278	4	55,8852	5371109	4	1,1919	8280135	4	0,2869
11076176	4	0,7000	5374883	4	0,4197	8285349	4	0,6671
11083888	4	0,3427	5374999	4	0,4579	8294484	4	1,0127
11084647	4	0,3117	5425950	4	0,3782	8298344	4	0,3029
11084782	4	0,5865	5459373	4	0,2866	8309175	4	0,2996
11127048	4	0,2993	5468295	4	0,3520	8330092	4	0,3217
11137143	4	0,3135	5511076	4	6,5132	8380743	4	2,0377
11151970	4	0,3116	5524325	4	0,6250	8386048	4	0,8174
11153627	4	0,5617	5543482	4	0,2948	8394040	4	0,3021
11175495	4	NaN	5557368	4	0,2979	8435247	4	0,6961
11190836	4	0,4040	5567438	4	0,5845	8455359	4	2,9637
11193447	4	0,6259	5606644	4	0,8619	8479107	4	0,7676
11198068	4	0,4002	5610698	4	4,1325	8481574	4	0,3269
11244501	4	0,2967	5611561	4	0,2587	8507080	4	0,5886
11246163	4	0,2792	5611763	4	0,3616	8545456	4	0,3152
11284547	4	0,2624	5615815	4	0,6742	8555573	4	0,3264
11288684	4	22,2101	5617953	4	0,2987	8561192	4	2,7426
11289003	4	0,3303	5620981	4	0,3335	8565912	4	1,0122
11295026	4	0,2909	5699617	4	0,2889	8579707	4	0,7886
11303416	4	0,3208	5774375	4	1,5500	8579812	4	0,6611
11305087	4	0,3093	5783368	4	1,8639	8587078	4	0,5841
11336707	4	0,2513	5783676	4	0,4014	8587792	4	0,3682
11347875	4	3,4551	5790912	4	0,3833	8590527	4	0,7398
11395117	4	0,3065	5821050	4	1,9334	8608310	4	0,9504
11395645	4	0,4969	5823121	4	2,2980	8647309	4	1,0220
11401845	4	2,1614	5872506	4	2,1261	8669092	4	1,0008
11403032	4	7,6316	5876360	4	1,0508	8677949	4	0,2850
11403776	4	0,4018	5877364	4	89,6485	8682849	4	0,3526
11404758	4	0,3512	5878081	4	0,5911	8685306	4	0,8081
11405559	4	0,2849	5878836	4	0,3549	8690104	4	0,4088
11413213	4	0,2375	5944240	4	2,5532	8694926	4	0,3715
11442348	4	0,3128	5951553	4	0,4320	8696327	4	0,8792

Tabla 29: Sistemas Kepler en Clase Predicha C4 (Mixed/Complex - Superposición) con su Período Orbital. Total: 581 sistemas. (parte 3)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
11457191	4	2,2984	5957123	4	2,8230	8703528	4	0,3999
11460346	4	0,3856	5961327	4	0,2992	8715667	4	0,4057
11496078	4	0,2997	5984000	4	0,3231	8719324	4	10,2327
11498689	4	0,3063	6029214	4	0,8191	8739802	4	0,2745
11502581	4	0,3336	6034812	4	0,3673	8803882	4	89,6302
11515292	4	3,4195	6044064	4	5,0632	8822555	4	0,8528
11566174	4	0,2769	6045264	4	0,9093	8842170	4	0,3494
11572643	4	0,3454	6048106	4	1,5594	8846978	4	1,3791
11604958	4	0,2989	6050116	4	0,2399	8904448	4	0,8660
11672319	4	0,3318	6057829	4	0,4834	8906676	4	8,2095
11704101	4	0,3449	6058875	4	1,1299	8934111	4	0,3645
11704155	4	0,2739	6061139	4	0,3224	8949316	4	0,6044
11716688	4	0,3012	6072195	4	2,8001	8956957	4	0,3244
11717798	4	0,3747	6103049	4	0,6432	8957887	4	0,3474
11769801	4	29,7082	6106771	4	0,2638	8982501	4	0,4145
11805235	4	0,3952	6118779	4	0,3642	8982514	4	0,4145
11819135	4	1,9016	6128248	4	0,2917	9005043	4	0,3202
11910076	4	0,3481	6143826	4	1,3548	9020289	4	0,3840
12019674	4	0,3545	6148271	4	1,7853	9021397	4	0,4262
12055517	4	NaN	6153219	4	0,5303	9026766	4	0,2721
12066630	4	1,0984	6205460	4	3,7228	9030509	4	0,4018
12071741	4	0,3143	6220497	4	1,3232	9053086	4	1,2748
12104285	4	0,2515	6224853	4	0,5360	9071373	4	0,4218
12109575	4	0,5317	6262882	4	0,9965	9085955	4	0,3592
12153332	4	0,2946	6264091	4	0,3250	9087918	4	0,4456
12216706	4	1,4711	6265720	4	0,3124	9091810	4	0,4797
12218858	4	0,4267	6281103	4	0,3633	9094335	4	0,3408
12257908	4	2,6159	6283224	4	0,7665	9097798	4	0,3341
12268220	4	4,4216	6292398	4	9,2399	9101400	4	1,6580
12305537	4	0,3618	6292925	4	13,6123	9110213	4	0,3371
12400729	4	0,9317	6302592	4	1,5780	9142964	4	0,5893
12418274	4	0,3527	6344429	4	0,4085	9145707	4	0,3208
12458797	4	0,2413	6359771	4	0,4061	9145846	4	0,2945
12598713	4	0,2572	6367628	4	3,7797	9151972	4	0,3868
12602985	4	0,2509	6368316	4	0,3385	9161428	4	0,3026
1433980	4	1,5926	6370558	4	60,3166	9179806	4	0,2810
2159783	4	0,3739	6424124	4	0,3855	9205993	4	1,2197
2161623	4	2,2835	6431545	4	0,3168	9237755	4	0,3317
2302092	4	0,2947	6436038	4	0,3763	9245929	4	0,3084
2437038	4	0,2677	6446219	4	0,4448	9268105	4	0,4257
2444187	4	0,3902	6467389	4	0,2890	9272276	4	0,2806
2447893	4	0,6616	6504095	4	0,3068	9274472	4	0,3021
2449084	4	0,7398	6516874	4	0,9163	9282687	4	1,6804
2450566	4	1,8446	6543674	4	2,3910	9283826	4	0,3565
2557430	4	1,2977	6615041	4	0,3401	9290838	4	0,3630
2570289	4	0,2790	6633929	4	0,3589	9291629	4	NaN
2571439	4	0,3210	6669809	4	0,7337	9307423	4	0,5586

Tabla 31: Sistemas Kepler en Clase Predicha C4 (Mixed/Complex - Superposición) con su Período Orbital. Total: 581 sistemas. (parte 4)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
2715007	4	0,2971	6671698	4	0,4715	9343862	4	1,1233
2715417	4	0,2364	6692340	4	0,6748	9345163	4	0,2451
2719436	4	0,7435	6766325	4	0,4400	9347868	4	0,3185
2854948	4	0,9743	6836140	4	0,4877	9388303	4	0,2667
2858322	4	0,4364	6843507	4	0,3432	9412114	4	0,2503
2972514	4	0,5035	6852488	4	2,1720	9450883	4	0,3637
2988984	4	0,7130	6853229	4	0,4261	9451598	4	0,3623
2996347	4	0,3010	6863161	4	1,9866	9479460	4	2,0739
3114667	4	0,8886	6865626	4	0,7268	9481674	4	0,3889
3119295	4	0,4397	6929869	4	0,2837	9514070	4	0,6073
3124420	4	0,9490	6948815	4	1,5415	9519590	4	0,3309
3218683	4	0,7717	6966265	4	0,3134	9527167	4	0,2809
3232823	4	0,4239	7023917	4	0,7728	9533508	4	0,3735
3342425	4	0,3934	7035139	4	0,3097	9551200	4	0,7119
3431321	4	1,0150	7041856	4	4,0007	9591358	4	0,4567
3437800	4	0,3627	7060333	4	2,5272	9593528	4	1,8866
3442006	4	1,4679	7107567	4	0,8126	9639265	4	0,5064
3448245	4	0,5135	7108433	4	1,5192	9651155	4	1,0738
3458919	4	0,8921	7117153	4	0,3595	9654476	4	0,3963
3547111	4	1,2078	7118621	4	0,3706	9655187	4	4,4162
3547874	4	19,6922	7118656	4	0,3214	9662581	4	0,2580
3549994	4	0,3472	7119757	4	0,7429	9700154	4	0,2573
3556229	4	0,7967	7119876	4	0,3664	9703626	4	0,4151
3557421	4	0,3937	7130044	4	0,2977	9711769	4	12,9359
3633901	4	0,8074	7173910	4	0,4022	9713664	4	0,3212
3732732	4	0,3962	7176440	4	0,3583	9767392	4	2,9145
3735597	4	1,9664	7199183	4	0,3241	9772642	4	0,2754
3743834	4	0,2736	7199353	4	0,2820	9777987	4	0,2585
3756730	4	0,3792	7204041	4	0,3317	9784230	4	0,7982
3764714	4	NaN	7217866	4	0,4072	9784371	4	3,3012
3832382	4	0,2726	7259917	4	0,3847	9786017	4	4,4980
3837677	4	0,4620	7269797	4	0,2818	9786798	4	0,4455
3839964	4	0,2561	7269843	4	0,2682	9821078	4	8,4294
3851320	4	1,2386	7284688	4	0,6460	9821923	4	0,3495
3853259	4	0,2766	7304911	4	0,6256	9832227	4	0,4579
3869825	4	4,8007	7339123	4	0,3471	9832545	4	1,0207
3935319	4	0,3531	7339345	4	0,2597	9838047	4	0,4362
3936357	4	0,3692	7367833	4	0,2862	9843435	4	1,6847
3945892	4	8,1665	7368451	4	0,3734	9882280	4	0,2891
3956545	4	0,3303	7378178	4	0,6243	9899216	4	10,9158
3956881	4	0,6969	7387296	4	2,5795	9899345	4	1,3326
3965242	4	0,9967	7432479	4	0,4085	9934052	4	0,3522
3972629	4	0,2442	7506446	4	0,3526	9935245	4	0,7849
4036687	4	0,2998	7512381	4	0,4239	9935311	4	0,2738
4066203	4	0,3625	7521682	4	0,3566	9944907	4	0,6134
4138301	4	0,2534	7529123	4	0,3501	9947924	4	0,3628

Tabla 33: Sistemas Kepler en Clase Predicha C4 (Mixed/Complex - Superposición) con su Período Orbital. Total: 581 sistemas. (parte 5)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
4150136	4	9,4784	7533807	4	0,3168	9948201	4	0,3032
4168013	4	0,3109	7542091	4	0,3905	9954225	4	1,3407
4244929	4	0,3414	7584826	4	0,6223	9991887	4	0,3224
4245897	4	11,2578	7597095	4	0,3012	9994475	4	0,3184
4249218	4	0,3162	7601767	4	0,4867	9995660	4	0,4186
4349483	4	0,5091	7610340	4	1,5177	9995981	4	0,2933
4350454	4	0,9657	7627059	4	0,3237			

Tabla 35: Sistemas Kepler en Clase Predicha C5 (Abrupt Change - Cambio Súbito) con su Período Orbital. Total: 148 sistemas.

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
10000490	5	1,4010	4921906	5	0,2137	7830460	5	3,3978
10063044	5	1,0097	4936680	5	0,6662	7938468	5	7,2270
10084115	5	0,3057	4937217	5	0,4293	7938870	5	0,5807
10095469	5	0,6778	4941060	5	0,3034	7959612	5	0,2432
10351767	5	0,6351	4949770	5	1,5641	7973882	5	0,3466
10389982	5	0,4440	5218385	5	0,2815	8045121	5	0,2632
10395609	5	0,3643	5282464	5	0,4964	8074045	5	0,5364
10616829	5	1,0729	5294739	5	3,7360	8094140	5	0,7064
10723143	5	0,3076	5310435	5	4,9314	8155368	5	0,7186
10789421	5	0,7769	5390351	5	0,5475	8189196	5	2,3041
10797126	5	0,4324	5475624	5	1,0698	8285970	5	0,5625
10848807	5	0,3462	5478466	5	0,4825	8367007	5	0,2516
10861842	5	0,4719	5560831	5	0,8677	8428136	5	0,4681
10919564	5	0,4621	5623923	5	1,2087	8431389	5	0,3511
10934755	5	0,7865	5685072	5	0,2559	8626039	5	0,2829
10979669	5	0,9258	5770431	5	0,3924	8841616	5	1,6796
11013201	5	0,2274	5786545	5	0,2806	8971432	5	0,6244
11038312	5	0,5456	5802834	5	1,0924	9007918	5	1,3872
11076279	5	1,4726	5955731	5	1,0038	9032671	5	0,2496
11154110	5	0,5297	5960283	5	0,2497	9077796	5	0,2381
11245381	5	0,3070	5962514	5	1,5801	9083523	5	0,9184
11341950	5	0,2884	5975712	5	1,1361	9101279	5	1,8115
11904038	5	0,6322	6066379	5	1,3039	9151763	5	438,0519
12109845	5	0,8660	6144827	5	0,2346	9164694	5	1,1114
12164751	5	2,6301	6187893	5	0,7892	9181877	5	0,3210
12356746	5	1,0049	6206751	5	1,2453	9238207	5	0,2314
12404615	5	0,3663	6213131	5	0,5614	9345838	5	1,0459
12554536	5	0,6845	6267702	5	0,2832	9353234	5	1,4865
1433410	5	0,2833	6287172	5	0,2039	9357030	5	0,2804
1572353	5	0,2289	6470516	5	2,0804	9365025	5	0,9843
2305372	5	1,4047	6471048	5	0,2972	9389122	5	0,3500
2435971	5	0,2718	6507541	5	0,3272	9392331	5	0,2618
2556127	5	0,4189	6794131	5	1,6133	9470175	5	0,3038
2854432	5	0,3223	6844489	5	1,0798	9474485	5	1,0252
2860594	5	5,4999	7037319	5	0,5781	9533706	5	0,2841
3245776	5	1,4921	7097571	5	2,2140	9541127	5	0,5367
3454864	5	0,2941	7137798	5	2,2535	9602595	5	3,5565
3560212	5	0,3461	7220320	5	0,7522	9612468	5	0,1335
3730067	5	0,2941	7368103	5	2,1825	9637239	5	0,7730
3745184	5	0,3042	7431703	5	0,5725	9639491	5	0,3445
4037163	5	0,6354	7440742	5	0,2840	9664382	5	0,2908
4074708	5	0,3021	7457163	5	0,7746	9692336	5	0,6879
4077442	5	0,6928	7458285	5	0,6606	9706078	5	0,6136
4241946	5	0,2844	7506164	5	0,5580	9717924	5	0,3956
4458989	5	0,5299	7516345	5	0,4919	9786165	5	0,3326

Tabla 37: Sistemas Kepler en Clase Predicha C5 (Abrupt Change - Cambio Súbito) con su Período Orbital. Total: 148 sistemas.(parte 2)

KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)	KIC	Clase Idx.	Período (d)
4464999	5	0,4342	7518816	5	0,4666	9833806	5	0,3932
4547308	5	0,5769	7546791	5	0,2424	9899416	5	1,3326
4670267	5	2,0061	7590728	5	0,4767	9957351	5	0,4956
4678875	5	1,8789	7657914	5	0,4745			
4904304	5	0,3895	7740302	5	1,1535			